

Nom : JAN

Prénom : Capucine

Groupe TD : Maths - Eco

16,75

Contrôle Continu - Statistiques descriptives - L1 EG

Consignes : Répondre aux questions posées en précisant lorsque cela est pertinent : la formule utilisée, les sommes intermédiaires. Précisez également l'interprétation des résultats obtenus.

Durée indicative : 1h15

Exercice 1 : On considère deux séries statistiques x et y mesurées pour différents individus notés i . Calculez la covariance entre ces deux variables. Interprétez.

i	x_i	y_i				
1	11	35				
2	15	50				
3	9	40				
4	15	45				
5	20	35				
moyenne	70	205				
moyenne	14	41				

~~$$\text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n \sum_{j=1}^n (x_i - \bar{x})(y_j - \bar{y})$$~~

$$\text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

$$\text{or } \bar{x} = \frac{1}{5} \sum_{i=1}^5 x_i \quad \text{d'où } \bar{x} = \frac{1}{5} \times 70 = 14$$

$$\bar{y} = \frac{1}{5} \sum_{i=1}^5 y_i \quad \text{d'où } \bar{y} = \frac{1}{5} \times 205 = 41$$

$$\text{d'où } \text{Cov}(X, Y) = \frac{1}{5} ((11-14)(35-41) + \dots + (20-14)(35-41))$$

$$\text{soit } \text{Cov}(X, Y) = \frac{1}{5} \times 0 = 0$$

la covariance entre ces deux variables est égale à 0
cela peut dire que les deux variables x et y ne sont
en aucun cas liées, ou alors qu'elles s'annulent

Exercice 1 : Une enquête menée auprès d'un échantillon de 275 individus permet d'obtenir le tableau de contingence suivant croisant la variable « âge » et la variable « Abonnement » désignant le nombre d'abonnements simultanés à des plateformes de streaming video (Netflix, OCS, Prime video, etc.). Nous souhaitons étudier l'existence d'un lien entre l'âge et les abonnements multiples.

Age/Abonnements	0	1	2	3	$n_{i.}$	$f_{i.}$		
20	19	14	8	4	45	0,16		
30	28	34	45	11	118	0,43		
45	43	36	26	7	112	0,41		
$n_{.j}$	90	84	79	22	275			
$f_{.j}$	0,33	0,31	0,29	0,08				

1. Quelle est la nature de la variable « Abonnements » ? Justifiez.

0,1 la variable "abonnements" est quantitative discrète car elle est représentée par une suite de chiffres entiers. (0, 1, 2, 3)

2. Quelle est la proportion d'individus de l'échantillon ayant 1 abonnements et 20 ans ? Indiquez la notation et la formule.

0,1 $f_{ij} = \frac{n_{ij}}{n}$ soit $f_{20,1} = \frac{14}{275} \approx 0,05$ soit 5% de l'échantillon a 20 ans et possède 1 abonnement

3. Calculez et interprétez la fréquence de la modalité « 3 abonnements ».

1 $f_{.3} = \frac{n_{.3}}{n_{..}}$
 ou $n_{.3} = \sum_{i=1}^3 n_{i3}$ et $f_{.3} = \frac{22}{275} \approx 0,08$ soit 8%
 soit $n_{.3} = 4 + 11 + 7 = 22$
 8% de l'échantillon possède 3 abonnements

4. Quelle proportion des individus ayant 30 ans ne possède aucun abonnement ? Indiquez la notation, la formule et le résultat.

0,75 $f_{i/x} = \frac{n_{ij}}{n_{i.}}$
 soit ici $f_{30/0} = \frac{n_{30,0}}{n_{30.}}$ indices des lignes d'abonnement et colonnes en nom modalités
 soit $f_{30/0} = \frac{28}{118} \approx 0,24$ soit 24% des individus ayant 30 ans, n'ont pas d'abonnement

5. Quel est l'âge moyen des individus au sein de cet échantillon ?

1,5 $\bar{x} = \frac{1}{n_{..}} \sum_{i=1}^3 n_{i.} x_i$
 soit $\bar{x} = \frac{1}{275} (20 \times 45 + 30 \times 118 + 45 \times 112)$
 $= \frac{1}{275} \times (900 + 3540 + 5040)$
 $= \frac{1}{275} \times 9480$
 $\approx 34,47$
 En moyenne, les individus de cet échantillon, ont 34 ans.

6. Calculer l'écart-type marginal de l'âge. Interprétez.

on calcule la variance marginale :

$$V(X) = \frac{1}{n..} \sum_{i=1}^3 n_{i.} (x_i - \bar{x})^2$$

$$\begin{aligned} \text{soit } V(X) &= \frac{1}{275} (45(20 - 34,47)^2 + 118(30 - 34,47)^2 + 112(45 - 34,47)^2) \\ &= \frac{1}{275} (24\,199) \\ &\approx 88,00 \end{aligned}$$

2 d'où $\sigma(X) = \sqrt{V(X)}$
soit $\sigma(X) \approx 9,38$

En moyenne, les individus ont un âge écarté de plus ou moins 9,38 ans autour de la moyenne de 34 ans. C'est beaucoup.

7. Calculer la moyenne conditionnelle du nombre d'abonnements pour les individus ayant 30 ans. Sachant que les moyennes sont respectivement de 0,93 et 0,97 pour les individus ayant 20 ans et 45 ans, que peut-on en conclure ?

$$\overline{y_{i=30}} = \frac{1}{n_{i.}} \sum_{j=1}^4 y_{ij} n_{ij}$$

$$\begin{aligned} \text{soit } \overline{y_{i=30}} &= \frac{1}{118} (0 \times 28 + 1 \times 34 + 2 \times 45 + 11 \times 3) \\ &= \frac{1}{118} \times 157 \\ &\approx 1,33 \end{aligned}$$

2 1,33 > 0,97 > 0,93, on en conclut qu'en moyenne, les individus de 30 ans ont plus d'abonnements que les 20 ou 45 ans.

8. Calculer l'écart-type conditionnel du nombre d'abonnement pour les individus ayant 30 ans. Sachant que l'écart-type marginal du nombre d'abonnement est de 2 et la moyenne marginale de 1,2, que pouvez-vous dire sur les individus ayant 30 ans par rapport à l'ensemble des individus ?

$$V(y_i) = \frac{1}{n_{i.}} \sum_{j=1}^4 n_{ij} (y_{ij} - \overline{y_i})^2$$

$$\begin{aligned} \text{soit } V(y_{30}) &= \frac{1}{118} (28(0 - 1,33)^2 + 34(1 - 1,33)^2 + 45(2 - 1,33)^2 + 11(3 - 1,33)^2) \\ &= \frac{1}{118} \times 106,12104 \\ &\approx 0,90 \end{aligned}$$

d'où $\sigma(y_i) = \sqrt{V(y_i)}$ soit $\sigma(y_{30}) = \sqrt{0,90} \approx 0,934$

2 En moyenne, les individus de 30 ans ont plus ou moins 1 abonnement par rapport à la moyenne qui est de 1,2 abonnement. L'écart-type est donc bien inférieure à l'écart-type marginal. Donc les 30 ans sont un groupe plus homogène que composé à l'ensemble du groupe.

Exercice 2 : Le tableau ci-dessous répertorie le temps de trajet en minutes des étudiants d'une promotion par rapport à leur composante d'étude.

i	Distance minutes x_i	Effectif n_i	Effectif cumulé N_i	fréquences f_i	fréquences cumulées F_i	
1	[0; 5[	44	44	0,25	0,25	
2	[5; 10[	40	84	0,23	0,48	
3	[10; 15[	55	139	0,31	0,79	
4	[15; 30[	20	159	0,11	0,90	
5	[30; 60[	16	175	0,09	1	
		175				

- 1) Quel graphique est le plus adapté pour représenter la distribution des temps de trajet ? Que doit-on représenter en abscisses et en ordonnées ? Justifiez vos réponses. Attention, il n'est pas demandé de réaliser de graphique.

7.5
2 Pour représenter la distribution des temps de trajet, il faut utiliser un histogramme car x_i est une variable quantitative continue. En abscisses il y aura les classes de temps tandis qu'en ordonnées il y aura les fréquences f_i sachant que $f_i = \frac{n_i}{n}$. On utilise les fréquences plutôt que les effectifs car elles permettent une représentation plus fidèle.

$$f_i = \frac{n_i}{n}$$

- 2) Indiquez la classe médiane et déterminez le temps de trajet médian. Interprétez.

Il y a 5 classes donc $(\frac{5+1}{2} = 3)$ la 3ème classe est la classe médiane, c'est-à-dire que la classe [10; 15[est la classe médiane. Ainsi, le temps de trajet $n = \sum_{i=1}^5 n_i$ soit $n = 175$. Il y a 175 participants, pour trouver la classe médiane on cherche donc la classe dans laquelle se trouve le $(\frac{175+1}{2} = 88)$ 88ème participant.

on calcule les effectifs cumulés (cf tableau) on a 84 et 139 donc ce qui correspond à la classe [10; 15[. [10; 15[est donc la classe médiane. Ainsi le temps médian est le milieu de la classe médiane, soit $(\frac{10+15}{2} = 12,5)$ 12,5 minutes.

c'est à dire qu'il y a autant de participants qui ont fait la course en moins de 12,5 minutes que de participants ayant fait la course en plus de 12,5 minutes.

3) Déterminez la valeur du troisième quartile. Interprétez.

Le troisième quartile c'est la médiane de la partie supérieure de la médiane, soit $\frac{88+175+1}{2} = 132$ (ou $\frac{176}{4} + \frac{176}{2} = 132$)

on trouve donc le 132^{ème} participants.

on a $132 \in]84, 139]$

d'après les calculs de la 2^{ème} questions, le 3^{ème} quartile serait aussi à 12,5 minutes et donc un quart seulement des participants aurait fait un temps supérieur à 12,5 minutes
le résultat est faussé car le temps médian et le 3^{ème} quartile sont tous les deux dans la même classe de temps mais aux extrémités

Dans les faits, il est probable que le résultat médian soit proche de 10 min et le 3^{ème} quartil proche de 15 ans.