

Statistiques Descriptives

Durée : 2h

Documents non autorisés

Instructions

Le sujet se décompose en 3 parties. Le barème de chaque partie est indiqué. Les questions sont numérotées de 1 à 13 indépendamment des parties. **Vous répondrez aux questions sur votre copie en indiquant le numéro (de 1 à 13) sur votre copie.**

Pour la partie QCM (questions 1 à 5), vous indiquerez sur votre copie le numéro de la question et la lettre de la ou des réponse(s) qui vous semble(nt) vraie(s). Il y a nécessairement au moins une bonne réponse pour chaque question.

En ce qui concerne les questions de cours et l'exercice d'application, **il n'y a pas besoin de calculatrices** (c'est pour ça que vous n'en avez pas). Les nombres sont choisis pour avoir des calculs simples. Si vous obtenez en résultat une fraction irréductible donnez comme réponse cette fraction (cela ne veut pas dire que votre réponse est fausse).

×1 QCM (5 points)

×1. La somme des écarts des observations à la moyenne est

- (a) égale à la variance.
- ☒ (b) égale à 0.
- (c) égale à 1.
- (d) égale à l'écart-type.

×2. Pour tout échantillon, la médiane est égale

- (a) au 1er quartile.
- (b) au 3e quartile.
- ☒ (c) au 5e décile.
- (d) au 25e centile.

✕ 3. L'écart inter-quartile

- (a) correspond à l'écart entre le 3e quartile et la médiane.
- (b) contient autant d'observations qu'il y a d'observations inférieures à la médiane.
- ☒ (c) contient 25% des observations.
- ☒ (d) contient 75% des observations.

✕ 4. Soit deux variables X et Y avec p et q modalités respectivement. On note x_i et y_j ces modalités. Les moyennes conditionnelles de X selon elle-même sont

- (a) toutes égales à la moyenne de X .
- (b) égales à x_i pour chaque modalité.
- (c) impossible à définir.
- ☒ (d) égales aux moyennes conditionnelles de Y selon elle-même.

✕ 5. Soit deux variables X et Y . On considère le coefficient de corrélation linéaire entre ces deux variables.

- (a) Si le coefficient de corrélation linéaire est nul alors les variables sont indépendantes.
- (b) Si le coefficient de corrélation linéaire est élevé alors il existe un lien de causalité entre ces variables.
- ☒ (c) S'il existe un lien de causalité entre ces variables alors le coefficient de corrélation linéaire est élevé.
- ☒ (d) Le coefficient de corrélation linéaire est forcément positif.

pas forcément

NON

2 Questions de cours (10 points)

✕ 6. Soit une variable quantitative X regroupée par classes. On note la classe i comme $[e_i, e_{i+1}]$.

- ✕ • Donnez la formule de la densité des classes.
- ✕ • Donnez la formule du coefficient directeur de la droite de la fonction de répartition sur le morceau $[e_i, e_{i+1}]$.
- ✕ • Montrez que ces deux formules sont égales puis expliquez avec vos propres mots pourquoi.

✕ 7. Énoncez les trois propriétés de la variance vues en cours.

8. Soit deux variables quantitatives X et Y avec $Y = X - \bar{x}$.

- ✕ • Déterminez la moyenne de Y .

✕ • Montrez que $V(Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$.

- Montrez que la corrélation linéaire entre X et Y est égale à 1. Expliquez pourquoi ce résultat n'est pas surprenant.

9. Soit deux variables X et Y . Soit 100 observations de ces deux variables. On a les statistiques suivantes :

$$\begin{aligned}\bar{x} &= 5, \\ \bar{y} &= 10, \\ \sum_{i=1}^n x_i y_i &= 700, \\ V(X) &= 2.\end{aligned}$$

Quelle est la covariance entre X et Y ? Interprétez cette covariance. Calculez les paramètres $\hat{a}$ et $\hat{b}$ de la droite de régression linéaire obtenue par la méthode des moindres carrés.

10. Donnez une définition du coefficient de détermination. Pourquoi peut-on dire qu'il mesure la qualité d'une régression linéaire ?

✕ 3 Exercice d'application (5 points)

On considère les notes (sur 4) des étudiant-e-s à un exercice. Ces étudiant-e-s provenaient de deux groupes de TD (A et B).

†

Notes / Grpes	A	B
1	1	7
2	4	17
3	19	5
4	6	1

- ✕ 11. Quelle est la fréquence conjointe de l'observation ligne 4 et colonne A ? Qu'est-ce que cette fréquence représente ? Quelle est la fréquence marginale d'une note de 3 ?
- ✕ 12. Calculez la moyenne et la variance (en valeurs exactes) des notes pour les groupes A et B.
- ✕ 13. Calculez la moyenne globale.