

Statistiques Descriptives

Florian NAVARRO

13 janvier 2022

Table des matières

1	Introduction	4
1.1	Buts du cours	4
1.2	Vocabulaire	5
1.3	Notations	6
1.4	Présentation des données	6
2	Représentations graphiques	9
2.1	Fréquences	9
2.1.1	Variables qualitatives et diagramme en barres	9
2.1.2	Variables quantitatives discrètes et diagrammes en bâtons	11
2.1.3	Variables quantitatives continues et histogramme	12
2.2	Fréquences cumulées	14
2.2.1	Définitions et propriétés	14
2.2.2	Exemple avec variables discrètes	16
2.2.3	Exemple avec variables continues	16
3	Résumés numériques	20
3.1	Indicateurs de tendance centrale	20
3.1.1	Moyenne	20
3.1.2	Médiane	26
3.1.3	Quantiles	30
3.1.4	Mode	34
3.2	Indicateurs de dispersion	36
3.2.1	Etendue	36
3.2.2	Ecart absolu moyen	36
3.2.3	Variance et Ecart-type	37
3.2.4	Coefficient de variation	40
4	Statistiques bivariées	41
4.1	Tableau de contingence	41
4.1.1	Forme générale	42
4.1.2	Effectifs	42
4.1.3	Fréquences	43
4.1.4	Représentations	47
4.1.5	Indicateurs	49
4.1.6	Indépendance	52

4.2	Régression	53
4.2.1	Nuage de points	53
4.2.2	Covariance et coefficient de corrélation linéaire	55
4.2.3	Régression linéaire	58
4.2.4	Qualité de la régression	65
4.3	Causalité et corrélation : observations, faits et théories	71
5	Indices	72
5.1	Indices élémentaires	72
5.1.1	Propriétés de l'indice élémentaire	74
5.2	Indices synthétiques	74
5.2.1	Indice de valeurs, de prix et de quantités	75
5.2.2	Indices de Laspeyres	77
5.2.3	Indices de Paasche	78
5.2.4	Indices de Fisher	79
5.2.5	Propriétés	81
5.3	Hétérogénéité et qualité	82

1 Introduction

Débutons par une “boutade” :

$$\infty = 0.$$

Une infinité d’information non-traitée équivaut à zéro information. Manier de l’information c’est savoir la manipuler, la traiter, et juger de sa pertinence.

1.1 Buts du cours

L’objectif de ce cours est d’apprendre les traitements mathématiques de base pour manipuler et comprendre un grand nombre de données. Dans ce cours le traitement de mathématiques que l’on abordera consiste à faire un *résumé* de l’information. On peut faire l’analogie avec le résumé d’un texte littéraire sauf qu’ici le “texte” est statistiques. L’information qui se trouve dans les données brutes a besoin d’être synthétiser afin de pouvoir être transmise et comprise.

Pourquoi parle-t-on de statistiques *descriptives* ? On distingue de grand type d’études statistiques :

- La statistique descriptive,
- La statistique inférentielle.

Historiquement, les premières études statistiques étaient démographiques et donc de **populations**. Ce terme de population a été gardé par habitude pour désigner l’ensemble des objets qui sont pris en compte dans une étude statistiques.

Lors de l’étude d’une population on considère un **échantillon** de cette dernière. C’est à dire un sous-ensemble finie de la population (une petite partie quoi...).

En statistiques inférentielle l’objectif est d’étendre les conclusions que l’on obtient sur une l’échantillon à l’ensemble de la population. Ce ne sera pas l’objet de ce cours. Ca sera pour l’année prochaine.

En statistiques descriptive en revanche, on se contente de décrire l’échantillon en résumant mathématiquement l’information dont on dispose. On ne peut étendre cette information au reste de la population.

1.2 Vocabulaire

Avant de continuer avec ce cours notons quelques points de vocabulaire. Nous avons déjà vu ce qu'est une **population** et un **échantillon**.

Individu : un objet de l'échantillon

Variable : La (ou les) propriété(s) de l'individu que l'on considère. En d'autres termes, l'information dont on dispose pour chaque individu et qui a priori varie d'un individu à un autre.


On distingue plusieurs types de variables :

- Les variables **qualitatives** : des variables qui ne sont pas numériques ni quantifiables (ex : la couleur des yeux, la mention au bac etc)
- Les variables **quantitatives** : des variables numériques quantifiables (ex : la taille, l'âge, le salaire etc)

Au sein de ces deux groupes on distingue deux sous-groupes respectifs :

- Pour les variables qualitatives :
 - variables ordinales (qui peuvent être ordonnées, ex : la satisfaction client)
 - variables nominales (qui ne peuvent être ordonnées, ex : des couleurs)
- Pour les variables quantitatives :
 - variables discrètes (variables numériques entières, ex : le nombre de pièces d'un appartement)
 - variables continues (variables numériques réelles, ex : la température)

En résumé :



1.3 Notations

Nous ferons usage de différentes notations mathématiques usuelles. En vrac :

- $\mathbb{R}$: l'ensemble des nombres réels.
- $\mathbb{N}$: l'ensemble des nombres naturels.
- $\sum_{i=1}^n$: La somme pour les i allant de 1 à n
- $\in$: appartient à (comme dans $x \in \mathbb{R}$)
- $\forall$: “pour tout”, “quelque soit”
- Δx : variation de x
- $\exists$: il existe au moins un ...
- $\Leftrightarrow$: ...est équivalent à...
- $\Rightarrow$: implique que ...
- $[a : b]$ les valeurs allant de a à b (a et b incluses)
- $]a : b]$ les valeurs allant de a à b (a exclue et b incluses)

1.4 Présentation des données

On peut présenter les données de deux manières : individuelle ou agrégées.

Prenons un exemple de données. Considérons $n = 10$ étudiant·e·s en L1.

L'information qui nous intéresse est leur mention au bac (variable qualitative ordinale).

Une *présentation individuelle* est ainsi :

Individu i	1	2	3	4	5	6	7	8	9	10
Mention	AB	B	P	AB	TB	AB	AB	P	P	B

On a pour chaque individu la valeur prise par la variable.

Une *présentation agrégée* aura cette forme :

Mention	P	AB	B	TD
Effectifs	3	4	2	1

Pour chaque mention rencontrée dans notre échantillon nous avons le nombre d'étudiant·e·s qui ont obtenu cette mention. Nous avons agrégée les étudiant·e·s en fonction de leur mention.

Définition 1 : L'ensemble des valeurs possibles de la variable (ici les types de mention) s'appelle l'ensemble des *modalités*. Pour chaque modalité i on a n_i = effectifs de la modalité i . C'est à dire le nombre d'individus pour qui la variable prend la modalité i . Supposons p modalités

On a également $\sum_i^p n_i = n$. La somme des effectifs de chaque modalité est égal à la taille de notre échantillon.

Exemples pour des variables continues :

On considère $n = 20$ individus travaillant dans une entreprise et on s'intéresse à la variable quantitative âge que l'on classe selon des "classes d'âges".

i	1	2	3	4
Classe d'âge i	$[0; 20[$	$[20; 40[$	$[40; 60[$	$[60; 90[$
Effectifs n_i	6	5	5	4

On a bien $\sum_i^4 n_i = 6 + 5 + 5 + 4 = 20 = n$. On aurait pu également classer différemment les âges. Par exemple un autre tableau sur la base des mêmes données est le suivant :

i	1	2	3	4	5
Classe d'âge i	[10; 30[	[30; 40[	[40; 50[	[50; 60[	[60; 90[
Effectifs n_i	7	4	3	6	4

Avec encore $\sum_i^5 n_i = 20$.

Ces différentes classifications reposent sur des critères subjectifs. Néanmoins il faut respecter deux conditions pour établir des classes :

- non-chevauchement des classes
- les effectifs de chaque classes ne doivent pas être “trop grande”

Les faits statistiques n'existent pas, les chiffres en eux-même ne disent pas grand chose. L'expertise conduit l'analyse statistiques. Décider de certaines classes ou d'autres, de s'intéresser à telle ou telle variables, de considérer une variables quantitatives comme continues ou discrètes, sont des décisions qui s'appuient sur des théories et des connaissances au-delà de la statistiques, qui relèvent du domaine à l'étude.

2 Représentations graphiques

2.1 Fréquences

Définition 2 : Soit une variable X avec p modalités. Soit une modalité i donnée avec pour effectif n_i sur un échantillon de taille n . La fréquence de cette modalité est le réel compris entre 0 et 1 défini par :

$$f_i = \frac{n_i}{n}.$$

On a donc la relation : $\sum_i^p f_i = 1$.

En effet, on sait que

$$\sum_i^p n_i = n,$$

en divisant donc par n on a

$$\frac{1}{n} \sum_i^p n_i = \frac{n}{n},$$

soit

$$\sum_i^p \frac{n_i}{n} = 1.$$

2.1.1 Variables qualitatives et diagramme en barres

Exemple :

Soit $n = 50$ salariés d'une entreprise dont on étudie la variable qualitative nominale "moyen de transport" prenant 4 modalités :

- voiture (v)
- train (t)
- marche (m)
- bicyclette (b)

On obtient les résultats suivants :

i	1	2	3	4
Moyen de transport	v	t	m	b
Effectifs n_i	24	11	6	9
Fréquence f_i	0.48	0.22	0.12	0.18

Diagramme en barres : L'un des manière de représenter graphique ces données est d'utiliser un diagramme en barres :





Diagramme en secteurs : Une autre représentation est le diagramme en secteur (ou “camembert”). Il faut pour cela calculer l’angle correspondant à chaque modalité.

i	1	2	3	4
Moyen de transport	v	t	m	b
Fréquence f_i	0.48	0.22	0.12	0.18
Angle ($f_i \times 360$)	172.8	79.2	43.2	64.8



2.1.2 Variables quantitatives discrètes et diagrammes en bâtons


Exemple :

Soit $n = 50$ salariés dont on étudie la variable quantitative discrète : nombre de jours d'absence

i	1	2	3	4	5	6	7	8
Nb de jours x_i	0	1	2	3	4	5	6	7
Effectifs n_i	7	8	11	5	3	6	5	5
Fréquence f_i	0.14	0.16	0.22	0.10	0.06	0.12	0.10	0.10

Diagramme en bâtons :

Pour représenter les fréquences d'une variable quantitative discrète on utilisera un diagramme en bâtons.




2.1.3 Variables quantitatives continues et histogramme

Exemple :

Soit $n = 50$ individus répartis selon deux classes d'âges.


i	1	2
Classe d'âge	$[25; 30[$	$[30; 55[$
Effectifs n_i	25	25
Fréquence f_i	0.5	0.5

La première approche qui nous vient à l'esprit serait de faire la représentation suivante :



Malheureusement cette représentation ne traduit pas bien le fait que la première classe d'âge est bien plus concentrée que la seconde. Une deuxième idée, l'histogramme, prend en compte cette différence de *densité*.

Voilà ce que l'on aimerait obtenir :



Comment obtient-on cette densité ? La hauteur de ces deux rectangles se calcule en exigeant que chaque rectangle ait une aire égale à la *fréquence de la classe*.

De manière générale, si une classe $[e_i; e_{i+1}[$ a pour fréquence f_i , la densité d_i correspondante vérifie :

$$d_i \times (e_{i+1} - e_i) = f_i,$$

et donc

$$d_i = \frac{f_i}{e_{i+1} - e_i}.$$

L'utilisation de la densité et de l'histogramme nous permet d'avoir une représentation plus pertinente de l'information. On comprend directement en regardant l'histogramme que notre population a une plus grande proportion d'individu qui ont un âge entre 25 et 30ans qu'entre 30 et 35 par exemple.

Dans notre exemple, soit $i = 1$ la classe $[25; 30[$ et $i = 2$ la classe $[30; 55[$ on a

$$\begin{aligned} d_1 &= \frac{0.5}{30 - 25} = \frac{0.5}{5} = 0.1, \\ d_2 &= \frac{0.5}{55 - 30} = \frac{0.5}{25} = 0.02, \end{aligned}$$

2.2 Fréquences cumulées

Les fréquences nous permettent de représenter les proportions associés à différentes modalités. En utilisant les fréquences cumulées dans le cadre de variables quantitatives ou de variables qualitatives ordinales nous pourrions savoir quelle proportion des individus présente la modalité p ou inférieur à p .

2.2.1 Définitions et propriétés

Définition 3 : On appelle **fréquence cumulée** de la k^{eme} modalités (pour des variables numériques ou ordinales) le nombre réel :

$$F_k = f_1 + f_2 + \dots + f_k = \sum_{i=1}^k f_i,$$

où les f_i sont les fréquences des modalités inférieures à k . F_k représente la

proportion d'individu ayant une modalité inférieure ou égale à la k^e modalité.

Supposons maintenant que l'on souhaite savoir la proportion d'individus qui présente une modalité strictement supérieure à p . Une première solution est de faire la somme des fréquences des modalités supérieures à p . Mais on peut procéder autrement. En effet on sait que la somme des fréquences de toutes les modalités est égale à 1.

$$\sum_{i=1}^p f_i = 1.$$

Si on s'intéresse à la modalité k on peut réécrire l'expression précédente comme

$$\begin{aligned} \sum_{i=1}^k f_i + \sum_{i=k+1}^p f_i &= 1 \\ \Leftrightarrow \sum_{i=k+1}^p f_i &= 1 - \sum_{i=1}^k f_i. \end{aligned}$$

C'est à dire que la somme des fréquences des modalités strictement supérieures à p est égal à 1 moins la somme des fréquences des modalités inférieures ou égales à p .

Nous pouvons maintenant introduire le principe, très important en statistique, de **fonction de répartition** (empirique). Elle n'est définie que pour des variables quantitatives.

Définition 4 : On définit comme **fonction de répartition** la fonction notée F telle que

$$F : \mathbb{R} \rightarrow [0; 1].$$

$x \rightarrow F(x)$

C'est à dire une fonction qui peut associer à chaque nombre réel une valeur comprise entre 0 et 1, cette valeur étant la fréquence cumulée associée. Pour chaque x on obtient la proportion d'observation inférieure à x .

Propriétés :

La fonction de répartition a quelques propriétés notables :


- F est croissante sur $\mathbb{R}$,
- $\lim_{x \rightarrow \infty} F(x) = 1$,
- $\lim_{x \rightarrow -\infty} F(x) = 0$.

2.2.2 Exemple avec variables discrètes

Soit le tableau agrégé suivant donnant la répartition du nombre de jours d'absence dans une entreprise :

i	1	2	3	4	5	6	7	8	9	10	11	12
Nb de jours x_i	0	1	2	3	4	5	6	7	8	9	10	11
Effectifs n_i	1	4	4	8	14	7	4	4	2	1	0	1
Fréquence f_i	0.02	0.08	0.08	0.16	0.28	0.14	0.08	0.08	0.04	0.02	0	0.02
Fréq. cumulée	0.02	0.10	0.18	0.34	0.62	0.76	0.84	0.92	0.96	0.98	0.98	1

Nous pouvons tracer la fonction de répartition. Lorsque la variable est *discrète*, c'est une fonction croissante *en escalier*.




2.2.3 Exemple avec variables continues

Reprenons l'exemple précédent avec les deux classes d'âges :

i	1	2
Classe d'âge	$[25; 30[$	$[30; 55[$
Effectifs n_i	25	25
Fréquence f_i	0.5	0.5
Fréquence cumulée	0.5	1


Dans le cas d'une variable *continue*, la fonction de répartition est *continue*. Dans le cas présent, où le tableau est agrégé en classe, *si* on suppose que la répartition des observations dans chaque classe est uniforme alors le graphe de la fonction F est *continu, croissant et affine par morceaux*.

Pour cet exemple on a :



En supposant que la répartition des observations dans chaque classe est uniforme, cette représentation affine nous permet de retrouver des fréquences cumulée précises. Supposons que nous souhaitons savoir la proportion d'individu dans notre échantillon qui ont un âge inférieur ou égal à 42 ans. Cela revient à chercher " $F(42) = ?$ ". Nous pouvons répondre à cette question par *interpolation linéaire*.

La question que l'on se pose peut être représentée ainsi graphiquement :




Il nous faut alors pouvoir calculer $F(42)$. On sait que la fonction de répartition est *affine par morceaux*, c'est à dire qu'elle a la forme $F(x) = y = a \times x + b$ avec des valeurs de a et de b qui diffèrent pour chaque morceaux.

Le nombre a représente la *pente* (appelée aussi coefficient directeur) de la droite. C'est à dire de combien y augmente chaque fois que x augmente. Le nombre b représente *l'ordonnée à l'origine*. C'est à dire la valeur que prend y quand x est égal à 0.

On cherche à calculer $F(42) = a \times 42 + b$. Il nous faut donc déterminer a et b .

Si l'on a les informations sur au moins deux points de cette droite (ce qui est le cas sinon nous n'aurions pas pu la tracer) nous pouvons déterminer l'équation de cette droite.

Afin de déterminer la pente il suffit de déterminer le rapport entre la progression sur l'axe des y et la progression sur l'axe des x . "Pour monter de tant, de combien j'avance".



En utilisant les notations du graphique, cela revient à dire $a = \frac{\Delta y}{\Delta x}$. On a

$$\Delta y = 1 - 0.5 = 0.5,$$

$$\Delta x = 55 - 30 = 25.$$

On en conclut donc que $a = \frac{0.5}{25} = 0.02$ (on peut noter que c'est également la densité de la classe!). C'est à dire que pour chaque année entre 30 et 55 ans la fréquence cumulée augmente de 0.02 (ou 2%). On a donc $F(x) = 0.02 \times x + b$. Il nous reste à calculer b . Il suffit de prendre un point connu sur cette droite. Prenons le point (30,0.5). On sait que 30 correspond au x et que 0.5 correspond à $F(x)$. On a alors

$$0.5 = 0.02 \times 30 + b,$$

ce qui équivaut à

$$b = 0.5 - 0.02 \times 30 = -0.1.$$

On a donc à présent l'équation de la fonction de répartition pour des valeurs de x entre 30 et 55. Cette équation est

$$F(x) = 0.02 \times x - 0.1.$$

On peut enfin calculer $F(42) = 0.02 \times 42 - 0.1 = 0.74$. On sait donc à présent que 74% des individus de notre échantillon ont 42 ans ou moins. Et on peut alors déterminer que $1 - F(42) = 1 - 0.74 = 0.26$: 26% des individus de notre échantillon ont strictement plus de 42 ans.

3 Résumés numériques

Afin de pouvoir résumer numériquement un ensemble de données statistiques, on va utiliser ce que l'on appelle des *indicateurs*. Nous allons nous intéresser à deux types d'indicateurs :

- des indicateurs de *tendances centrales*,
- des indicateurs de *dispersion*.

Il existe d'autres types d'indicateurs (concentration, symétrie) mais nous ne les verrons pas dans ce cours.

3.1 Indicateurs de tendance centrale

Les indicateurs de tendance centrale ont pour objectif de donner une valeur qui soit représentative de l'ensemble des valeurs de l'échantillon. Ils renseignent donc sur l'ordre de grandeur de la variable considérée.

3.1.1 Moyenne

La moyenne est l'indicateur le plus connu et le plus utilisé (à tort parfois). La moyenne ne peut être calculée que pour des variables quantitatives. Nous allons voir comment la moyenne se calcule selon si la variable quantitative est discrète ou continue.

Données non-agrégées :

Usuellement les étudiant·e·s sont famili·er·ère·s du concept de moyenne quand nous traitons de données non-agrégées.

Supposons un·e étudiant·e qui a obtenu les notes suivantes : 12, 10, 12, 11. Instinctivement pour calculer sa moyenne nous ferions

$$\bar{x} = \frac{1}{4}(12 + 10 + 12 + 11) = 11.25.$$

Ainsi, si l'on est en présence de données non-agrégées on va définir la moyenne de manière simple :

Définition 5 : Soit une variable quantitative X ayant n observations $x_1, x_2, \dots, x_n$ la moyenne est définie comme

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Maintenant supposons que nous ayons des données agrégées. On a par exemple le tableau suivant :

i	1	2	3
Notes x_i	10	11	12
Effectifs n_i	1	1	2

En présence de ce tableau, pour calculer la moyenne nous calculons

$$\begin{aligned}\bar{x} &= \frac{1}{4}(10 + 11 + 12 + 12) \\ &= \frac{1}{4}(10 \times 1 + 11 \times 1 + 12 \times 2).\end{aligned}$$

L'effectif de chaque modalité vient pondérer la valeur de la note dans la moyenne. En présence de données agrégées nous introduisons donc une pondération correspondant à l'effectif pour chaque modalité, puisque cet effectif représente justement le nombre de fois que cette modalité apparaît dans la série brute des données.

Généralisons donc cette définition de la moyenne pour des données agrégées et selon si la variable quantitative est discrète ou continue.

Cas discret :

Soit X une variable discrète de modalités $x_1, x_2, \dots, x_p$ d'effectifs respectifs $n_1, n_2, \dots, n_p$ et de fréquences respectives $f_1, f_2, \dots, f_p$. Soit n l'effectif total. La moyenne de X est le nombre noté $\bar{x}$ défini par

$$\bar{x} = \frac{1}{n} \sum_{i=1}^p n_i \times x_i.$$

Elle est obtenue en multipliant chaque valeur des modalités de la variable par l'effectif associé, puis en faisant la somme de ces multiples. Enfin on divise cette somme par le nombre d'individus de l'échantillon. Nous faisons donc là ce qu'on appelle aussi une moyenne *pondérée*. Chaque modalité a un poids d'autant plus important que l'effectif de cette modalité est grande.

Exemple :

Si l'on reprend ce tableau du chapitre précédent. Soit $n = 50$ salariés dont on étudie le nombre de jours d'absence.

i	1	2	3	4	5	6	7	8
Nb de jours x_i	0	1	2	3	4	5	6	7
Effectifs n_i	7	8	11	5	3	6	5	5
Fréquence f_i	0.14	0.16	0.22	0.10	0.06	0.12	0.10	0.10

Le nombre de jours moyen d'absence se calcule donc de la manière suivante :

$$\begin{aligned}
\bar{x} &= \frac{1}{50} \sum_{i=1}^8 n_i \times x_i \\
&= \frac{1}{50} (0 \times 7 + 1 \times 8 + 2 \times 11 + 3 \times 5 + 4 \times 3 + 5 \times 6 + 6 \times 5 + 7 \times 5) \\
&= 3.04
\end{aligned}$$

On peut alors dire que pour l'échantillon considéré, chaque salarié a en moyenne 3.04 jours d'absence. On peut observer que malgré le fait que la variable soit discrète, la moyenne elle peut tout à fait ne pas être un nombre entier.

Propriétés :

1. On peut également calculer la moyenne $\bar{x}$ à partir des fréquences :

$$\bar{x} = \sum_{i=1}^p f_i \times x_i.$$

2. La somme des écarts des observations à la moyenne $(x_i - \bar{x})$ est nulle :

$$\sum_{i=1}^p n_i \times (x_i - \bar{x}) = 0.$$

Preuve :

Pour (1) : On a

$$\bar{x} = \frac{1}{n} \sum_{i=1}^p n_i \times x_i,$$

et on sait que $f_i = \frac{n_i}{n}$, par conséquent

$$\bar{x} = \sum_{i=1}^p \frac{n_i}{n} \times x_i = \sum_{i=1}^p f_i \times x_i.$$

Pour (2) : On a

$$\begin{aligned}
 \sum_{i=1}^p n_i \times (x_i - \bar{x}) &= \sum_{i=1}^p (n_i \times x_i - n_i \times \bar{x}) \\
 &= \sum_{i=1}^p n_i \times x_i - \sum_{i=1}^p n_i \times \bar{x} \\
 &= n \times \bar{x} - \bar{x} \sum_{i=1}^p n_i \\
 &= n \times \bar{x} - \bar{x} \times n = 0
 \end{aligned}$$

Propriété :

Si on effectue un changement affine sur les données on peut retrouver la moyenne en effectuant le même changement sur la moyenne. Soit une variable X de moyenne $\bar{x}$. Soit une nouvelle variable Y telle que $Y = a \times X + b$. Soit $\bar{y}$ la moyenne de Y . On a

$$\bar{y} = a \times \bar{x} + b.$$

Preuve :

$$\begin{aligned}
 \bar{y} &= \frac{1}{n} \sum_{i=1}^p n_i \times y_i = \frac{1}{n} \sum_{i=1}^p n_i \times (a \times x_i + b) \\
 &= a \times \frac{1}{n} \sum_{i=1}^p (n_i \times x_i) + \frac{1}{n} \sum_{i=1}^p n_i \times b \\
 &= a \times \frac{1}{n} \sum_{i=1}^p (n_i \times x_i) + \frac{b}{n} n \\
 &= a \times \bar{x} + b.
 \end{aligned}$$

Cas d'une variable continue :

Soit une variable X ayant pour classe de modalités

$$[e_1, e_2[, [e_2, e_3[, \dots, [e_p, e_{p+1}[$$

ayant pour effectifs $n_1, n_2, \dots, n_p$ et pour fréquences $f_1, f_2, \dots, f_p$.
La moyenne de X est le nombre noté $\bar{x}$ défini par

$$\bar{x} = \frac{1}{n} \sum_{i=1}^p n_i \times c_i,$$

avec $c_i = \frac{1}{2}(e_i + e_{i+1})$ le centre de la classe.

Exemple :

Reprenons l'exemple précédent avec les deux classes d'âges :

i	1	2
Classe d'âge	[25; 30[	[30; 55[
Effectifs n_i	25	25
Fréquence f_i	0.5	0.5

On calcule d'abord le centre de chaque classe :

$$c_1 = \frac{1}{2}(25 + 30) = 27.5$$

$$c_2 = \frac{1}{2}(30 + 55) = 42.5$$

On peut donc calculer la moyenne :

$$\bar{x} = \frac{1}{50}(27.5 \times 25 + 42.5 \times 25) = 35.$$

Propriétés :

Les propriétés sont les mêmes que pour le cas discret.


Interprétation variationnelle de la moyenne :

La moyenne $\bar{x}$ est l'unique valeur qui minimise la somme des carrés de ses écarts aux observations. On note cette quantité $D(x)$:

$$D(x) = \sum_{i=1}^n (x_i - x)^2.$$

Démonstration :

On cherche donc à minimiser la quantité $D(x)$. Graphiquement cela veut dire trouver le point x tel que :



C'est à dire le point pour lequel la dérivé première de $D(x)$ s'annule. On a donc, $\forall x \in \mathbb{R}$,

$$\begin{aligned}\frac{\delta D(x)}{\delta x} &= \sum_{i=1}^n 2 \times (-1) \times (x_i - x), \\ &= -2 \times \left[\sum_{i=1}^n x_i - \sum_{i=1}^n x \right], \\ &= -2 \times \left[\sum_{i=1}^n x_i - n \times x \right].\end{aligned}$$

Ainsi $\frac{\delta D(x)}{\delta x} = 0 \Leftrightarrow \sum_{i=1}^n x_i - n \times x = 0$ et donc

$$\begin{aligned}\sum_{i=1}^n x_i - n \times x &= 0, \\ \sum_{i=1}^n x_i &= n \times x, \\ \frac{1}{n} \sum_{i=1}^n x_i &= x, \\ \bar{x} &= x.\end{aligned}$$

La moyenne est donc bien la quantité qui minimise le carré de ses écarts avec les observations.

Un défaut de la moyenne :

La moyenne est malheureusement un indicateur extrêmement sensible aux valeurs extrêmes. Considérons par exemple les données suivantes

i	1	2	3	4
x_i	0	1	2	1000
n_i	33	33	33	1

La moyenne : $\bar{x} = \frac{1}{100}[0 \times 33 + 1 \times 33 + 2 \times 33 + 1000] = \frac{1099}{100} = 10.99$.

Un autre indicateur de tendance centrale moins sensible aux valeurs extrêmes existe : c'est la médiane.

3.1.2 Médiane

La médiane est un autre indicateur de tendance centrale qui est défini pour des variables quantitatives.

Définition 6 : Soit $x_1, x_2, \dots, x_n$, n observation d'une variable quantitative X .

La médiane, notée “Med” est une valeur observable de X telle qu'au moins 50% des valeurs observées soient inférieures à Med et au moins 50% des valeurs observées soient supérieures à Med. En d'autres termes, la médiane est la valeur observable qui “coupe” l'échantillon en deux parts égales.

On peut également définir la médiane en fonction de la fonction de répartition. Soit F la fonction de répartition de la variable X , la médiane Med vérifie

$$F(\text{Med}) = 0.5.$$

Exemple dans le cas discret :

Considérons neuf étudiant·e·s ayant obtenu les notes (sur 20) suivantes :

4, 4, 17, 19, 10, 11, 12, 14, 13.

Classons ces notes par ordre croissant :

4, 4, 10, 11, 12, 13, 14, 17, 19.

Dans cet exemple la médiane est égal à 12. C'est la note observée qui sépare les observations en deux parts égales. La moitié des étudiant-e-s ont obtenu une note inférieure ou égale à 12 et l'autre moitié une note supérieure ou égale à 12. Avec un nombre impair d'observation, la médiane est très simple à définir.

Qu'en est-il quand nous avons un nombre pair d'observation ? Supposons que nous rajoutons une autre note à nos données : 8.


4, 4, 8, 10, 11, 12, 13, 14, 17, 19.

Nous n'avons à présent plus une unique observation qui sépare les observations en deux. Nous avons un couple médian, ou intervalle médian : $[11, 12]$. Dans ce cas, la médiane est définie comme étant égale à $\frac{(11+12)}{2} = 11.5$, le milieu de cet intervalle.


Reprenons à présent l'exemple des jours d'absence dans l'entreprise pour nous intéresser au lien entre fonction de répartition et médiane dans le cas discret. Nous avons le tableau suivant :

i	1	2	3	4	5	6	7	8	9	10	11	12
Nb de jours x_i	0	1	2	3	4	5	6	7	8	9	10	11
Effectifs n_i	1	4	4	8	14	7	4	4	2	1	0	1
Fréquence f_i	0.02	0.08	0.08	0.16	0.28	0.14	0.08	0.08	0.04	0.02	0	0.02
Fréq. cumulée	0.02	0.10	0.18	0.34	0.62	0.76	0.84	0.92	0.96	0.98	0.98	1

qui nous donnait la fonction de répartition suivante :



Par définition, la médiane est la valeur observée de la variable telle que $F(Med) = 0.5$, cependant la fonction de répartition étant ici une fonction en escalier et aucune observation n'a une fréquence cumulée d'exactly 0.5. Par convention, la médiane est alors la première observation dont la fréquence cumulée dépasse 0.5. Graphiquement :




Exemple dans le cas d'une variable continue :

Dans le cas continu, la médiane est toujours exactement déterminée grâce

à la fonction de répartition. Prenons l'exemple suivant. On considère $n = 20$ individus travaillant dans une entreprise et on s'intéresse à leur âge. On a les classes suivantes :

i	1	2	3	4
Classe d'âge	$[0; 20[$	$[20; 40[$	$[40; 60[$	$[60; 90[$
Effectifs n_i	6	5	5	4
Fréquence f_i	0.3	0.25	0.25	0.2
Fréq cumulée F_i	0.3	0.55	0.8	1



On cherche donc l'âge x tel que $F(x) = 0.5$. On voit que la médiane doit se situer dans la classe $[20; 40[$. Cette classe va être ce qu'on appelle la classe médiane. La fonction de répartition est définie ici par morceau. Il va nous falloir déterminer l'équation de la droite sur le morceau $[20; 40[$. On va procéder comme précédemment. L'équation est de la forme $y = a \times x + b$.

Le coefficient directeur a de la droite entre $[e_i; e_{i+1}]$ est égal à $\frac{F_i - F_{i-1}}{e_{i+1} - e_i}$. Ici on a $e_i = 20$ et $e_{i+1} = 40$. On obtient alors un coefficient directeur de

$$a = \frac{F_i - F_{i-1}}{e_{i+1} - e_i} = \frac{0.55 - 0.3}{40 - 20} = 0.0125.$$

Afin de trouver l'ordonnée à l'origine b nous allons remplacer x et y dans l'équation par, respectivement l'âge et la fréquence cumulée d'un point connu

sur cette droite. Prenons le point $(20, 0.3)$. On a alors

$$\begin{aligned} 0.3 &= 0.0125 \times 20 + b \Leftrightarrow b = 0.3 - 0.0125 \times 20 \\ &\Leftrightarrow b = 0.3 - 0.25 = 0.05. \end{aligned}$$

L'équation de la fonction de répartition sur le morceau $[20; 40[$ est donc : $y = 0.0125 \times x + 0.05$, avec y la fréquence cumulée et x l'âge. Écrit autrement : $F(\text{âge}) = 0.0125 \times \text{âge} + 0.05$. On cherche alors l'âge tel que $F(\text{âge}) = 0.5$ (ou on cherche x tel que $F(x) = 0.5$ c'est exactement la même chose). On pose

$$\begin{aligned} 0.5 &= 0.0125 \times x + 0.05 \\ 0.45 &= 0.0125 \times x \\ \frac{0.45}{0.0125} &= x \\ x &= 36. \end{aligned}$$

La médiane est donc de 36. C'est à dire que dans l'entreprise étudiée, la moitié des salariés ont 36 ans ou moins et l'autre moitié 36 ans ou plus.

Interprétation variationnelle :

Soit une variable quantitative X prenant les valeurs $x_1, x_2, \dots, x_n$. La médiane Med est l'unique valeur x qui minimise la somme des valeurs absolues de ses écarts aux observations. On note cette quantité $E(x)$:

$$E(x) = \sum_{i=1}^n |x_i - x|.$$

3.1.3 Quantiles

Nous avons vu que la médiane est définie comme la valeur observée x telle que $F(x) = 0.5$. Nous pouvons étendre cette idée à différents points de la fonction de répartition. On parle alors de *quantiles*. Les quantiles sont des valeurs qui permettent de partager les observations ordonnées en sous-groupes contenant les même nombre de données (à l'arrondi près).

La médiane est le quantile qui sépare les observations en deux groupes de parts égales.

Les *quartiles* séparent les observations en quatre groupes égaux.

Les *déciles* en dix groupes égaux.

Définition 7 : Soit une variable quantitative X et sa fonction de répartition F , le quantile d'ordre q est défini par

$$F(x_q) = q,$$

avec $0 \leq q \leq 1$. Si $q = 0.5$ on définit la médiane.


- Les **quartiles** sont les valeurs qui partagent les observations en quatre groupes égaux. Il existe donc 3 quartiles : $q_1 = 0.25$, $q_2 = 0.5$, $q_3 = 0.75$. Le deuxième quartile est la médiane.
- Les **déciles** partagent la distribution en 10. Il existe 9 déciles notés $d_1, \dots, d_9$. $d_1 = 0.1$, $d_2 = 0.2$ etc.
- Les **centiles** partagent la distribution en 100 parts égales.

Exemple pour une variable discrète :

Reprenons l'exemple discret précédent du nombre de jours d'absence et déterminons les quartiles.

i	1	2	3	4	5	6	7	8	9	10	11	12
Nb de jours x_i	0	1	2	3	4	5	6	7	8	9	10	11
Effectifs n_i	1	4	4	8	14	7	4	4	2	1	0	1
Fréquence f_i	0.02	0.08	0.08	0.16	0.28	0.14	0.08	0.08	0.04	0.02	0	0.02
Fréq. cumulée	0.02	0.10	0.18	0.34	0.62	0.76	0.84	0.92	0.96	0.98	0.98	1

Cet exemple nous donnait la fonction de répartition suivante :



Les quartiles sont donc 3 jours, 4 jours et 5 jours. 25% des observations correspondent à 3 jours d'absence ou moins, 50% des observations correspondent à 4 jours d'absence ou moins et 75% des observations correspondent à 5 jours d'absence ou moins.


Nous avons également le résultat suivant : 50% des observations se situent entre 3 jours et 5 jours d'absence. C'est ce que l'on appelle **l'écart inter-quartile** ($q_3 - q_1$) qui contient donc 50% des observations. L'écart interdécile ($d_9 - d_1$) contient 80% des observations. L'écart intercentile ($c_{99} - c_1$) contient 98% des observations etc.

Exemple pour une variable continue :


En présence d'une variable continue, il va falloir potentiellement déterminer les équations des différents morceaux de la fonction de répartition où se situent les quantiles qui nous intéressent.

Si l'on reprend l'exemple de tout à l'heure :

i	1	2	3	4
Classe d'âge	$[0; 20[$	$[20; 40[$	$[40; 60[$	$[60; 90[$
Effectifs n_i	6	5	5	4
Fréquence f_i	0.3	0.25	0.25	0.2
Fréq cumulée F_i	0.3	0.55	0.8	1



et que l'on souhaite calculer les quartiles il va falloir déterminer les équations de la fonction de répartition pour le morceau $[0; 20[$, $[20; 40[$ et $[40; 60[$: ce sont les morceaux qui contiennent les observations ayant une fréquence cumulée respectivement de 0.25, 0.5 et 0.75.



3.1.4 Mode


Dans les sections précédentes les indicateurs de tendance centrale que nous avons étudiés sont tous définis uniquement pour des variables quantitatives ou qualitatives ordinales. Mais qu'en est-il des variables qualitatives nominales ? Un indicateur définissable pour tout type de variables, quantitatives ou qualitatives est le **mode**.

Définition 8 : Le **mode** d'une série d'observation est la valeur qui correspond à l'effectif ou à la fréquence le (la) plus élevé(e). C'est la valeur la plus fréquemment rencontrée dans un échantillon.

Variable qualitatives :

Reprenons l'exemple des moyens de transport des salariés d'une entreprise et le diagramme en barre correspondant

i	1	2	3	4
Moyen de transport x_i	v	t	m	b
Effectifs n_i	24	11	6	9
Fréquence f_i	0.48	0.22	0.12	0.18




Le mode est donc la modalité de la variable qualitative la plus fréquente. Ici c'est la modalité "v" (pour voiture). On peut dire que le type de transport

le plus fréquent pour les salariés de cette entreprise est la voiture.

Variable quantitative discrète :

Reprenons à nouveau l'exemple du nombre de jours d'absence dans l'entreprise et le diagramme en bâtons associé.

i	1	2	3	4	5	6	7	8
Nb de jours x_i	0	1	2	3	4	5	6	7
Effectifs n_i	7	8	11	5	3	6	5	5
Fréquence f_i	0.14	0.16	0.22	0.10	0.06	0.12	0.10	0.10



On observe, à la fois dans le tableau et sur le diagramme, que le nombre de jours d'absence le plus fréquent est 2. C'est donc le mode de cette variable. Cette variable ne présente qu'un seul mode, on dira donc que la distribution de cette variable est *unimodale*.

Il est possible qu'une variable présente plusieurs valeurs, consécutives ou non, pour lesquelles la fréquence est la plus élevée.

Si ces valeurs sont consécutives on parle d'*intervalle modal* dont les bornes correspondent à ces deux valeurs. Si cette variable présente deux modes on dira que sa distribution est *bimodale*. Si elle en présente plus, on dira que sa distribution est *plurimodale*. La présence de plusieurs modes est indicatif de

l'hétérogénéité de nos données.

Variable quantitative continue :

Les données étant regroupées par classe, on détermine alors la **classe modale** qui est donc la classe ayant l'effectif ou la fréquence la plus élevée. Dans l'exemple :

i	1	2	3	4
Classe d'âge	$[0; 20[$	$[20; 40[$	$[40; 60[$	$[60; 90[$
Effectifs n_i	6	5	5	4
Fréquence f_i	0.3	0.25	0.25	0.2

la classe modale est $[0; 20[$.

3.2 Indicateurs de dispersion

Les indicateurs de dispersion nous permettent d'étudier la fluctuation des observations autour d'une valeur centrale (le plus souvent la moyenne). Dans l'ensemble de cette section, par simplicité, les définitions se réfèrent à des séries d'**observations non-agrégées**.

3.2.1 Etendue

L'indicateur de dispersion "naïf" est l'étendue.

Définition 9 : Soit une variable quantitative X , l'étendue est définie comme la différence entre la plus grande et la plus petite valeur observée.

L'étendue est un concept très simple mais présente l'inconvénient de ne dépendre que des valeurs extrêmes observées. C'est le plus souvent une mesure très imparfaite de la dispersion.

3.2.2 Ecart absolu moyen

L'écart absolu moyen est un indicateur plus sophistiqué. Il mesure la dispersion des observations en faisant la moyenne des valeurs absolues des écarts de chaque observation à la moyenne de l'échantillon.

Définition 10 : Soit une variable quantitative X avec $x_1, x_2, \dots, x_n$ les n valeurs observés de X . Soit $\bar{x}$ la moyenne de X . L'écart absolu moyen, noté EAM est défini comme

$$EAM = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|.$$

Exemple :

Supposons un·e étudiant·e qui a obtenu les notes suivantes : 12, 10, 12, 11. Nous avons 4 observations.

i	1	2	3	4
x_i (notes)	12	10	12	11

Sa moyenne est de 11.25. L'écart absolu moyen se calcule donc ainsi

$$\begin{aligned} EAM &= \frac{1}{4} \sum_{i=1}^4 |x_i - 11.25| = \frac{1}{4} (|12 - 11.25| + |10 - 11.25| + |12 - 11.25| + |11 - 11.25|) \\ &= \frac{1}{4} (0.75 + 1.25 + 0.75 + 0.25) \\ &= 0.75. \end{aligned}$$

Cet indicateur nous apporte une information sur la dispersion des observations. Elles se situent en moyenne à 0.75 points de la moyenne de 11.25 (elles sont donc plutôt proche de la moyenne et peu dispersée).

3.2.3 Variance et Ecart-type

La variance et l'écart-type sont deux autres indicateurs de dispersion. Ce sont les indicateurs les plus utilisés. Ils ressemblent dans leur construction à l'écart absolu moyen. Ils sont liés entre eux par une relation directe.

Définition 11 : Soit une variable quantitative X avec $x_1, x_2, \dots, x_n$ les n observations de X . Soit $\bar{x}$ la moyenne. La variance, notée $V(X)$, est le nombre réel défini par

$$V(X) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

L'écart-type, noté $\sigma(X)$, est lui défini par

$$\sigma(X) = \sqrt{V(X)}.$$

Remarque : La variance est donc la moyenne des écarts $((x_i - \bar{x}))$ quadratiques (au carré) à la moyenne. Là où l'écart absolu moyen et la moyenne des écarts absolus.

La variance mesure la dispersion. L'écart-type donne l'écart standard d'une observation par rapport à la moyenne. Si les données sont en mètres, l'écart-type sera en mètre et la variance en m^2 .

Exemple :

Supposons un·e étudiant·e qui a obtenu les notes suivantes : 12, 10, 12, 11. Nous avons 4 observations.

i	1	2	3	4
x_i (notes)	12	10	12	11

Sa moyenne est de 11.25. La variance se calcule donc ainsi :

$$\begin{aligned} V(X) &= \frac{1}{4} \sum_{i=1}^4 (x_i - 11.25)^2 = \frac{1}{4} \left((12 - 11.25)^2 + (10 - 11.25)^2 + (12 - 11.25)^2 + (11 - 11.25)^2 \right) \\ &= \frac{1}{4} \left(0.5625 + 1.5625 + 0.5625 + 0.0625 \right) = 0.6875 \end{aligned}$$

L'écart-type est égal à

$$\sigma(X) = \sqrt{V(X)} = \sqrt{0.6875} = 0.8291$$

L'écart-type se mesure dans la même unité que les observations. Ainsi on peut dire que les notes de cet élève se situe avec un écart standard de 0.8291 points autour de la moyenne. La variance nous renseigne sur la dispersion. Plus la variance est élevée, plus dispersion est forte et inversement.

Propriétés :

1. $V(X) \geq 0$.

$$2. V(X) = \frac{1}{n} \sum_{i=1}^n (x_i^2) - \bar{x}^2 = \bar{x}^2 - \bar{x}^2.$$

$$3. \text{ Si } Y = a \times X + b \text{ alors } V(Y) = a^2 \times V(X) \text{ et } \sigma(Y) = |a| \times \sigma(X).$$

Preuve :

La propriété 1 est évidente du fait des propriétés du carré.

Pour la propriété 2 :

$$\begin{aligned} V(X) &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n (x_i^2 - 2 \times x_i \bar{x} + \bar{x}^2) \\ &= \frac{1}{n} \sum_{i=1}^n (x_i^2) - 2 \bar{x} \times \frac{1}{n} \sum_{i=1}^n (x_i) + \frac{1}{n} \sum_{i=1}^n (\bar{x}^2) \\ &= \frac{1}{n} \sum_{i=1}^n (x_i^2) - 2 \bar{x} \times \bar{x} + \frac{1}{n} n (\bar{x}^2) \\ &= \frac{1}{n} \sum_{i=1}^n (x_i^2) - 2 \bar{x}^2 + \bar{x}^2 \\ V(X) &= \frac{1}{n} \sum_{i=1}^n (x_i^2) - \bar{x}^2. \\ V(X) &= \bar{x}^2 - \bar{x}^2. \end{aligned}$$

Pour la propriété 3 :

$$\begin{aligned}
V(Y) &= \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{1}{n} \sum_{i=1}^n \left[(a x_i + b) - (a \bar{x} + b) \right]^2 \\
&= \frac{1}{n} \sum_{i=1}^n \left[a x_i + b - a \bar{x} - b \right]^2 \\
&= \frac{1}{n} \sum_{i=1}^n \left[a (x_i - \bar{x}) \right]^2 \\
&= \frac{1}{n} \sum_{i=1}^n a^2 (x_i - \bar{x})^2 \\
&= a^2 \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \\
&= a^2 V(X).
\end{aligned}$$

Par conséquent on a également, pour l'écart-type

$$\begin{aligned}
\sigma(Y) &= \sqrt{V(Y)} = \sqrt{a^2 V(X)} \\
&= a \sigma(X).
\end{aligned}$$

3.2.4 Coefficient de variation

Si nous étudions des données dans une certaine unité de mesure, nous avons vu que l'écart-type sera exprimée dans cette unité et la variance dans le carré de cette unité. Si nous souhaitons comparer la dispersion de deux séries d'observations de variables qui sont exprimés dans différentes unités nous ne pouvons pas comparer les variances et écart-type (ex : différence de dispersion entre les salaires dans deux pays ayant des devises différentes). Le **coefficient de variation** permet de produire un indicateur indépendant des unités de mesures qui permet alors la comparaison. Il est défini comme le rapport entre l'écart-type et la moyenne.

Définition 12 : Soit une variable quantitative X avec $x_1, x_2, \dots, x_n$ les n observations de X . Soit $\bar{x}$ la moyenne et $\sigma(X)$ l'écart-type. Le coefficient de variation CV est déterminé par :

$$CV(X) = \frac{\sigma(X)}{\bar{x}}.$$

4 Statistiques bivariées

Dans ce chapitre nous allons nous pencher sur l'observations de deux variables simultanément. A partir du moment où on s'intéresse deux variables, par exemple le niveau de diplôme et la catégorie socio-professionnelles des parents, on peut s'interroger sur l'existence d'un liens entre les deux variables. Dans un premier temps nous nous intéresserons à des couples de variables qualitatives et quantitatives discrètes que l'on représente dans un tableau de contingence. Ensuite nous nous intéresserons à des couples de variables quantitatives continues pour lesquels nous analyserons les liens de corrélation et conduirons une analyse de régression.

4.1 Tableau de contingence

Commençons par un exemple. Considérons le tableau suivant qui regroupe des données sur l'origine sociale des étudiants en 2011-2012.

Origine sociale \ Filière	Droit	Economie	Lettres	Sciences	Santé	IUT	Total
Agriculteurs	2 543	2 665	5 508	4 788	2 999	2 755	21 258
Artisans, comm., chefs d'e.	15 384	12 029	22 819	16 379	11 784	9 549	87 944
Prof. lib., cadres sup.	60 732	34 867	91 046	72 033	74 984	29 620	363 282
Prof. int	18 008	14 666	47 672	33 135	20 887	16 862	151 230
Employés	19 984	17 186	47 543	30 359	14 173	15 323	144 568
Ouvriers	15 192	16 601	39 061	27 097	10 406	14 990	123 347
Retraités, inactifs	24 368	21 506	58 154	27 257	16 119	9 415	156 819
Non renseigné	14 850	20 685	49 079	23 579	30 201	4 921	139 315
Total	171 061	140 205	356 882	234 627	181 553	103 435	1 187 763

L'échantillon est ici composée de 1 187 763 étudiant·e·s inscrit·e·s à l'université en 2011-2012. Chaque individus (ici un·e étudiant·e) est représenté par deux variables : sa filière et son origine sociale (CSP des parents). Le tableau représente donc des données agrégées.

On appelle ce type de tableau un tableau à double entrée, ou tableau à deux dimensions ou encore **tableau de contingence**. Dans ce tableau les lignes représentent l'origine sociale. Nous avons 8 modalités pour l'origine

sociale. En colonnes nous avons les filières des étudiants, avec 6 modalités. Ces données sont donc des données qualitatives nominales.

Les lignes et colonnes “Total” sont aussi appelés les **marges** du tableau. Ce tableau nous renseigne à la fois sur la distribution des étudiant·e·s en terme de filières et également en terme d’origine sociale. Il peut être lu de deux façons. Prenons le chiffre 15 192 situé à la sixième ligne et première colonne. Il porte les deux informations suivantes :

- Parmi les 171 061 étudiant·e·s en droit, 15 192 sont issus du milieu Ouvrier.
- Parmi les 123 347 étudiant·e·s issu·e·s du milieu Ouvrier présent·e·s à l’université, 15 192 sont en droit.

4.1.1 Forme générale

Considérons un échantillon de n individus. Chaque individu est représenté par deux variables X et Y dont les modalités sont respectivement $x_1, x_2, \dots, x_p$ et $y_1, y_2, \dots, y_q$. X a donc p modalités et Y a q modalités. Chaque individu présente donc un couple de modalités (x_i, y_j) (avec $i \in [1 : p]$ et $j \in [1 : q]$) qu’on observe chez cet individu. On compte alors le nombre d’individus qui présentent ce couple particulier (x_i, y_j) . Cet effectif associé au couple (x_i, y_j) est noté n_{ij} .

On reporte ces informations dans un tableau de contingence où x est associé aux lignes et y aux colonnes.

$X \setminus Y$	y_1	y_2	$\dots$	y_j	$\dots$	y_q	Total
x_1	n_{11}	n_{12}	$\dots$	n_{1j}	$\dots$	n_{1q}	$n_{1\bullet}$
x_2	n_{21}	n_{22}	$\dots$	n_{2j}	$\dots$	n_{2q}	$n_{2\bullet}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
x_i	n_{i1}	n_{i2}	$\dots$	n_{ij}	$\dots$	n_{iq}	$n_{i\bullet}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
x_p	n_{p1}	n_{p2}	$\dots$	n_{pj}	$\dots$	n_{pq}	$n_{p\bullet}$
Total	$n_{\bullet 1}$	$n_{\bullet 2}$	$\dots$	$n_{\bullet j}$	$\dots$	$n_{\bullet q}$	$n_{\bullet \bullet}$

4.1.2 Effectifs

Dans les marges lignes (resp. colonne) du tableau, l’indice correspondant à la colonne (resp. ligne) est remplacé par un point. Ainsi, pour la ligne i du

tableau, la valeur $n_{i\bullet}$ représente la somme des effectifs de la ligne i .

$$n_{i\bullet} = n_{i1} + n_{i2} + \cdots + n_{iq} = \sum_{j=1}^q n_{ij}, \quad \forall i \in [1; p].$$

Ces grandeurs sont appelés les **effectifs marginaux** de X .

De la même manière pour la colonne j du tableau, la valeur $n_{\bullet j}$ représente la somme des effectifs de la colonne j .

$$n_{\bullet j} = n_{1j} + n_{2j} + \cdots + n_{pj} = \sum_{i=1}^p n_{ij}, \quad \forall j \in [1; q].$$

Ces grandeurs sont appelés les **effectifs marginaux** de Y .

La valeur $n_{\bullet\bullet}$ représente la somme des effectifs marginaux de X pour toutes les lignes, soit

$$n_{\bullet\bullet} = n_{1\bullet} + n_{2\bullet} + \cdots + n_{p\bullet} = \sum_{i=1}^p \sum_{j=1}^q n_{ij} = n.$$

On obtient le même résultat en considérant la valeur $n_{\bullet\bullet}$ comme la somme des effectifs marginaux de Y pour toutes les colonnes. La valeur $n_{\bullet\bullet}$ représente l'effectif total.

4.1.3 Fréquences

De la même manière que nous avons calculé des fréquences pour les statistiques univariées (à une seule variable), il est possible de calculer les fréquences pour les statistiques bivariées. Nous distinguerons trois types de fréquences : la *fréquence conjointe*, la *fréquence marginale* et la *fréquence conditionnelle*.

Pour la **fréquence conjointe** nous allons donc associer à chaque case du tableau une fréquence. C'est à dire nous allons calculer la proportion du couple de modalités des deux variables au sein de l'échantillon.

Définition 13 : Soit deux variables X et Y ayant respectivement p et q modalités $x_1, x_2, \dots, x_p$ et $y_1, y_2, \dots, y_q$. Soit n_{ij} l'effectif de l'observation caractérisé par le couple de modalités (x_i, y_j) . La fréquence conjointe qui correspond à la proportion d'individus dans l'échantillon présentant à la fois les

Origine sociale \ Filière	Droit	Economie	Lettres	Sciences	Santé	IUT	Total
Agriculteurs	0.21%	0.22%	0.46%	0.40%	0.25%	0.23%	1.79%
Artisans, comm., chefs d'e.	1.30%	1.01%	1.92%	1.38%	0.99%	0.80%	7.40%
Prof. lib., cadres sup.	5.11%	2.94%	7.67%	6.06%	6.31%	2.49%	30.59%
Prof. int	1.52%	1.23%	4.01%	2.79%	1.76%	1.42%	12.73%
Employés	1.68%	1.45%	4.00%	2.56%	1.19%	1.29%	12.17%
Ouvriers	1.28%	1.40%	3.29%	2.28%	0.88%	1.26%	10.38%
Retraités, inactifs	2.05%	1.81%	4.90%	2.29%	1.36%	0.79%	13.20%
Non renseigné	1.25%	1.74%	3.80%	1.99%	2.54%	0.41%	11.73%
Total	14.40%	11.80%	30.05%	19.75%	15.29%	8.71%	100%

FIGURE 1 – Fréquence conjointe de l'origine sociale et de la filière.

modalités x_i et y_j est notée f_{ij} et est définie par

$$f_{ij} = \frac{n_{ij}}{n} = \frac{n_{ij}}{n_{\bullet\bullet}}, \quad \forall i \in [1 : p], \quad \forall j \in [1 : q].$$

Exemple :

Pour le tableau précédent sur l'origine sociale des étudiant·e·s, on obtient alors le tableau Figure 1.

On peut ainsi en conclure que les étudiant·e·s provenant d'un milieu agricole qui étudient l'économie représentent 0.22% de l'ensemble des étudiant·e·s.

Propriétés : La fréquence conjointe a les propriétés suivantes

— Le total des fréquences de la ligne i est donné par :

$$f_{i\bullet} = \sum_{j=1}^q f_{ij} = \sum_{j=1}^q \frac{n_{ij}}{n} = \frac{n_{i\bullet}}{n}, \quad \forall i \in [1 : p].$$

— Le total des fréquences de la colonne j est donné par :

$$f_{\bullet j} = \sum_{i=1}^p f_{ij} = \sum_{i=1}^p \frac{n_{ij}}{n} = \frac{n_{\bullet j}}{n}, \quad \forall j \in [1 : q].$$

— La somme des fréquences est égal à 1 :

$$\sum_{i=1}^p \sum_{j=1}^q f_{ij} = \sum_{i=1}^p f_{i\bullet} = \sum_{j=1}^q f_{\bullet j} = 1.$$

Les fréquences $f_{i\bullet}$ et $f_{\bullet j}$ sont donc obtenues en faisant le rapport entre les effectifs marginaux et l'effectif total. On appelle ces fréquences les **fréquences marginales**. La fréquence marginale $f_{i\bullet}$ (resp. $f_{\bullet j}$) est la fréquence empirique de la modalité x_i (resp. y_j) de la variable X (resp. Y). Ainsi, en reprenant les données de notre tableau des fréquences on peut dire que

- $f_{3\bullet} = \frac{n_{3\bullet}}{n} = \frac{363282}{1187763} = 0.3059 : 30.59\%$ des étudiant·e·s inscrit·e·s à la fac en 2011-2012 venaient d'un milieu de professions libérales et cadres supérieurs.
- $f_{\bullet 2} = \frac{n_{\bullet 2}}{n} = \frac{140205}{1187763} = 0.1180 : 11.80\%$ des étudiant·e·s inscrit·e·s à la fac en 2011-2012 étaient inscrit·e·s dans une filière d'économie.

Les fréquences marginales peuvent être comparées aux fréquences dans le cas de statistiques univariée. La distribution des modalités de la variable X ne fait pas intervenir la variable Y .

On peut cependant considérer simultanément l'information des deux variables. On va alors parler de **fréquences conditionnelles**. Elle va permettre de répondre à des questions de la forme : “Quelle part des étudiant·e·s inscrit·e·s en économie provient d'un milieu ouvrier?”. Elles permettent de croiser l'information.

Définition 14 : Soit deux variables X et Y ayant respectivement p et q modalités $x_1, x_2, \dots, x_p$ et $y_1, y_2, \dots, y_q$. Soit n_{ij} l'effectif de l'observation caractérisé par le couple de modalités (x_i, y_j) . La fréquence conditionnelle de X par rapport à Y représentant la proportion d'individus présentant la modalité x_i parmi les individus présentant la modalité y_j est notée $f_{i/j}^{X/Y}$ et est défini par

$$f_{i/j}^{X/Y} = \frac{n_{ij}}{n_{\bullet j}}, \forall i \in [1 : p].$$

De la même manière, la fréquence conditionnelle de Y par rapport à X représentant la proportion d'individus présentant la modalité y_j parmi les individus présentant la modalité x_i est notée $f_{j/i}^{Y/X}$ et est défini par

$$f_{j/i}^{Y/X} = \frac{n_{ij}}{n_{i\bullet}}, \forall j \in [1 : q].$$

Origine sociale \ Filière	Droit	Economie	Lettres	Sciences	Santé	IUT
Agriculteurs	1.49%	1.90%	1.54%	2.04%	1.65%	2.66%
Artisans, comm., chefs d'e.	8.99%	8.58%	6.39%	6.98%	6.49%	9.23%
Prof. lib., cadres sup.	35.50%	24.87%	25.51%	30.70%	41.30%	28.64%
Prof. int	10.53%	10.46%	13.36%	14.12%	11.50%	16.30%
Employés	11.68%	12.26%	13.32%	12.94%	7.81%	14.81%
Ouvriers	8.88%	11.84%	10.95%	11.55%	5.73%	14.49%
Retraités, inactifs	14.25%	15.34%	16.30%	11.62%	8.88%	9.10%
Non renseigné	8.68%	14.75%	12.63%	10.05%	16.63%	4.76%
Total	100%	100%	100%	100%	100%	100%

FIGURE 2 – Fréquence conditionnelle de l'origine sociale selon la filière.

Les fréquences conditionnelles sont donc différentes selon si on envisage les fréquences de X selon Y ou de Y selon X . On a donc deux tableaux différents.

Ce premier tableau représente donc les fréquences conditionnelles de l'origine sociale selon la filières (en terme générique de X selon Y). On peut donc y lire le type d'information suivant :

- $f_{5/2}^{X/Y} = \frac{n_{52}}{n_{\bullet 2}} = \frac{17186}{140205} = 0.1226$: 12.26% des étudiant·e·s inscrit·e·s en économie provenaient de la CSP employés.
- $f_{4/3}^{Y/X} = \frac{n_{43}}{n_{\bullet 3}} = \frac{47672}{356882} = 0.1336$: 13.36% des étudiant·e·s inscrit·e·s en lettres provenaient de la CSP professions intermédiaires.

Le second tableau est celui-ci :

Origine sociale \ Filière	Droit	Economie	Lettres	Sciences	Santé	IUT	Total
Agriculteurs	11.96%	12.54%	25.91%	22.52%	14.11%	12.96%	100%
Artisans, comm., chefs d'e.	17.49%	13.68%	25.95%	18.62%	13.40%	10.86%	100%
Prof. lib., cadres sup.	16.72%	9.60%	25.06%	19.83%	20.64%	8.15%	100%
Prof. int	11.91%	9.70%	31.52%	21.91%	13.81%	11.15%	100%
Employés	13.82%	11.89%	32.89%	21.00%	9.80%	10.60%	100%
Ouvriers	12.32%	13.46%	31.67%	21.97%	8.44%	12.15%	100%
Retraités, inactifs	15.54%	13.71%	37.08%	17.38%	10.28%	6.00%	100%
Non renseigné	10.66%	14.85%	32.36%	16.92%	21.68%	3.53%	100%

FIGURE 3 – Fréquence conditionnelle de la filière selon l'origine sociale.

Ce second tableau représente donc les fréquences conditionnelles de la filière selon l'origine sociale (en terme générique de Y selon X). On peut donc y lire le type d'information suivant :

- $f_{2/5}^{X/Y} = \frac{n_{52}}{n_{5\bullet}} = \frac{17186}{144568} = 0.1189 : 11.89\%$ des étudiant·e·s provenant de la CSP employés étudient l'économie.
- $f_{3/4}^{Y/X} = \frac{n_{43}}{n_{4\bullet}} = \frac{47672}{151230} = 0.3152 : 31.52\%$ des étudiant·e·s provenaient de la CSP professions intermédiaires étaient inscrit·e·s en lettres.

Propriétés : Les fréquences conditionnelles ont les propriétés suivantes

- La somme des fréquences conditionnelles est égal à 1

$$\sum_{i=1}^p f_{i/j}^{X/Y} = \sum_{i=1}^p \frac{n_{ij}}{n_{\bullet j}} = \frac{n_{\bullet j}}{n_{\bullet j}} = 1.$$

Et


$$\sum_{j=1}^q f_{j/i}^{Y/X} = \sum_{j=1}^q \frac{n_{ij}}{n_{i\bullet}} = \frac{n_{i\bullet}}{n_{i\bullet}} = 1.$$

- Les fréquences conditionnelles, marginales et conjointes sont liées par la relation suivante :

$$f_{ij} = f_{i\bullet} \times f_{j/i}^{Y/X} = f_{\bullet j} \times f_{i/j}^{X/Y}.$$

4.1.4 Représentations

Pour le types de variables que nous étudions dans cette section (qualitatives et quantitatives discrètes) les données peuvent être représentées par des diagrammes en barres empilés ou des diagrammes par secteurs. Les données du tableau des effectifs peuvent être représentées par le diagramme suivant



La hauteur d'une des barres du diagramme indique l'effectif total de l'origine sociale correspondante. La taille des sections au sein de chaque barre indique le nombre d'étudiant·e·s de cette origine inscrit·e·s dans différentes filières. Ainsi si l'on regarde la barre des professions libérales et cadres pour avoir lire l'information relative aux étudiant·e·s de cette CSP concernant la filière de l'économie il faut considérer la taille du rectangle correspondant et non sa hauteur totale par rapport à l'axe.

4.1.5 Indicateurs

Dans le cas où au moins une des variables considérées dans le tableau de contingence est quantitative, on est en mesure de calculer des indicateurs tels que la moyenne et la variance. Prenons comme exemple le tableau de contingence théorique suivant. Nous avons une variable X avec 3 modalités et une variable Y avec 2 modalités.

$X \setminus Y$	0	1	Total
1	4	6	10
2	10	2	12
3	8	15	23
Total	22	23	45

Indicateurs des fréquences marginales :

Soit X et Y deux variables quantitatives, ayant respectivement p et q modalités $x_1, x_2, \dots, x_p$ et $y_1, y_2, \dots, y_q$. Soit n_{ij} l'effectif de l'observation caractérisée par le couple de modalités (x_i, y_j) , on peut définir les indicateurs suivants

— La moyenne marginale de X :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^p n_{i\bullet} x_i = \sum_{i=1}^p f_{i\bullet} x_i.$$

— La moyenne marginale de Y :

$$\bar{y} = \frac{1}{n} \sum_{j=1}^q n_{\bullet j} y_j = \sum_{j=1}^q f_{\bullet j} y_j.$$

— La variance marginale de X :

$$V(X) = \frac{1}{n} \sum_{i=1}^p n_{i\bullet} (x_i - \bar{x})^2.$$

— La variance marginale de Y :

$$V(Y) = \frac{1}{n} \sum_{j=1}^q n_{\bullet j} (y_j - \bar{y})^2.$$

Dans cet exemple on a :

$$\bar{x} = \frac{1}{45} (10 \times 1 + 12 \times 2 + 23 \times 3) = 2.288$$

$$\bar{y} = \frac{1}{45} (22 \times 0 + 23 \times 1) = 0.511$$

$$V(X) = \frac{1}{45} (10 \times (1 - 2.288)^2 + 12 \times (2 - 2.288)^2 + 23 \times (3 - 2.288)^2) = 0.649$$

$$V(Y) = \frac{1}{45} (22 \times (0 - 0.511)^2 + 23 \times (1 - 0.511)^2) = 0.249$$

Ces indicateurs des fréquences marginales nous renseignent sur les variables indépendamment l'une de l'autre. Elles nous donnent ici la moyenne et la variance des valeurs observées des variables X et Y comme on les obtiendrait si on avait séparément deux études univariées pour chacune des variables.

Indicateurs des fréquences conditionnelles :

Soit X et Y deux variables quantitatives, ayant respectivement p et q modalités $x_1, x_2, \dots, x_p$ et $y_1, y_2, \dots, y_q$. Soit n_{ij} l'effectif de l'observation caractérisé par le couple de modalités (x_i, y_j) , on peut définir les indicateurs suivants

— La moyenne conditionnelles de X selon Y :

$$\bar{x}_j = \frac{1}{n_{\bullet j}} \sum_{i=1}^p n_{ij} x_i = \sum_{i=1}^p f_{i/j}^{X/Y} x_i, \quad \forall j.$$

— La moyenne conditionnelles de Y selon X :

$$\bar{y}_i = \frac{1}{n_{i\bullet}} \sum_{j=1}^q n_{ij} y_j = \sum_{j=1}^q f_{j/i}^{Y/X} y_j, \quad \forall i.$$

— La variance conditionnelles de X selon Y :

$$V_j(X) = \frac{1}{n_{\bullet j}} \sum_{i=1}^p n_{ij} (x_i - \bar{x}_j)^2, \quad \forall j.$$

— La variance conditionnelles de Y selon X :

$$V_i(Y) = \frac{1}{n_{i\bullet}} \sum_{j=1}^q n_{ij} (y_j - \bar{y}_i)^2, \quad \forall i.$$

La moyenne conditionnelle $\bar{x}_j$ est donc la moyenne des X pour les individus qui présentent la modalité j de la variable Y .

Dans cet exemple on a pour la moyenne et la variance conditionnelle des X selon la modalité 0 de la variable Y :

$$\bar{x}_0 = \frac{1}{22} (4 \times 1 + 10 \times 2 + 8 \times 3) = 2.182,$$

$$V_0(X) = \frac{1}{22} (4 \times (1 - 2.182)^2 + 10 \times (2 - 2.182)^2 + 8 \times (3 - 2.182)^2) = 0.512$$

Pour la moyenne et la variance conditionnelle des Y selon la modalité 2 de la variable X on a :

$$\bar{y}_2 = \frac{1}{12} (10 \times 0 + 2 \times 1) = 0.1667.$$

$$V_2(Y) = \frac{1}{12} (10 \times (0 - 0.1667)^2 + 2 \times (1 - 0.1667)^2) = 0.138$$

Ces indicateurs sont des indicateurs conditionnels. La valeur $\bar{x}_0$ nous donne la moyenne pour les valeurs de X *uniquement des individus qui présentent la modalité 0 de la variable Y* .

La valeur $\bar{y}_2$ nous donne la moyenne des valeurs de Y pour les individus qui présentent la modalité 2 de la variable X . On peut d'ailleurs observer qu'en moyenne les individus ayant la modalité 2 de la variable X ont une valeur de Y beaucoup plus faible ($\bar{y}_2 = 0.1667$) que la moyenne générale des Y ($\bar{y} = 0.511$).

Propriétés : Il existe des relations entre les moyennes marginales et conditionnelles ainsi qu'entre les variances marginales et conditionnelles.

— Relations entre les moyennes :

$$\bar{x} = \frac{1}{n} \sum_{j=1}^q n_{\bullet j} \bar{x}_j,$$

$$\bar{y} = \frac{1}{n} \sum_{i=1}^p n_{i \bullet} \bar{y}_i.$$

La moyenne de X (resp. Y) est égal à la moyenne des moyennes conditionnelles de X selon Y (resp. de Y selon X).

— Relations entre les variances :

$$V(X) = \frac{1}{n} \sum_{j=1}^q n_{\bullet j} (\bar{x}_j - \bar{x})^2 + \frac{1}{n} \sum_{j=1}^q n_{\bullet j} V_j(X),$$

$$V(Y) = \frac{1}{n} \sum_{i=1}^p n_{i\bullet} (\bar{y}_i - \bar{y})^2 + \frac{1}{n} \sum_{i=1}^p n_{i\bullet} V_i(Y).$$

ou encore

$$V(X) = V(\bar{x}_j) + \overline{V_j(X)},$$

$$V(Y) = V(\bar{y}_i) + \overline{V_i(Y)}.$$

La variance marginale est égale à la variance des moyennes conditionnelles ajoutée à la moyenne des variances conditionnelles. La dispersion de la variable Y dépend donc à la fois de la dispersion des moyennes conditionnelles à Y et de la dispersion des valeurs autour de leur moyennes conditionnelles.

4.1.6 Indépendance

En présence d'une étude à deux variables, on peut voir apparaître trois types de liaisons entre les variables :

- Si les deux variables ne présentent aucun lien entre elles on dira qu'elles sont *indépendantes*. C'est à dire que les valeurs des variables n'ont pas d'influence l'une sur l'autre. Dans le cas d'un tableau de contingence de deux variables indépendantes, les fréquences conditionnelles sont égales aux fréquences marginales

$$f_{i/j}^{X/Y} = f_{i\bullet}, \quad \forall i \text{ et } f_{j/i}^{Y/X} = f_{\bullet j}, \quad \forall j,$$

et les moyennes marginales et conditionnelles sont égales.

- Si on observe que pour chaque valeur de X on a toujours la même valeur de Y et inversement on dira que les deux variables sont *parfaitement dépendantes*. Dans ce cas les moyennes conditionnelles d'une variable sont égales à la valeur unique prise par la variable conditionnellement.

- En pratique, les données tombent le plus souvent entre ces deux cas extrêmes. Les variables ne sont pas parfaitement indépendantes mais ne sont pas non plus parfaitement dépendantes. On va alors parler de corrélation. Si les deux variables évoluent conjointement (ex : quand X augmente, Y augmente) on parlera de corrélation positive. Si les deux variables évoluent de manière opposée (ex : quand X augmente, Y diminue) on parlera de corrélation négative. L'analyse de régression qui suit nous permettra de rentrer plus dans les détails.

4.2 Régression

Pour l'analyse de régression nous allons nous intéresser à des statistiques bivariées avec un couple de variables quantitatives continues.


4.2.1 Nuage de points

on considère un échantillon de n individus. On étudie le couple de variables quantitatives X et Y . Chaque individu i dispose de deux données numériques (x_i, y_i) . Les deux variables étant quantitatives les valeurs x_i et y_i pour chaque individu i prennent une valeur numériques. On peut alors les lire comme des *coordonnées* dans un repère et représenter l'ensemble des données graphiquement.

Par exemple, prenons les données suivantes

Individu i	1	2	3	4	5	6	7	8	9
x_i	0.9	2.2	1.8	2.9	2.8	3.5	4.5	5	5.6
y_i	0.9	1.8	4	4	4.6	0.9	1.6	4.1	4.9

On peut placer l'individu 1 au point $(0.9, 0.9)$ sur un graphique. L'individu 2 au point $(2.2, 1.8)$ etc.




On appelle cette représentation le **nuage de points**.

Comme nous l'avons vu à la section précédente nous pouvons calculer les moyennes séparément pour les deux variables X et Y . Ces deux moyennes peuvent également servir de coordonnées. En notant $\bar{x}$ et $\bar{y}$ respectivement les moyennes des valeurs prises par X et Y on obtient le **point moyen** (ou centre de gravité) G que l'on peut placer aux coordonnées $(\bar{x}, \bar{y})$. Ce point représente alors l'individu moyen. Dans l'exemple ci-dessus on a

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = 3.24,$$

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = 2.98.$$



En présence de statistiques bivariées, le problème central est celui du lien entre les deux variables. Ce problème se décompose en deux questions. La première est celle de la corrélation entre les deux variables, existe-t-il un lien statistique entre les deux grandeurs ? La seconde est celle de la quantification de ce lien s'il existe. Peut-on établir une équation mathématique reliant les deux variables nous permettant ainsi d'estimer la valeur d'une des deux variables grâce à l'autre ?

Nous allons d'abord nous intéresser à la première question grâce aux outils que sont la covariance et le coefficient de corrélation linéaire. L'analyse de régression nous permettra d'attaquer la seconde question.

4.2.2 Covariance et coefficient de corrélation linéaire

Un des indicateurs le plus utilisé pour mesurer le lien entre deux variables est la **covariance**.

Définition 15 : Soit un échantillon de n individus. Soit deux variable quantitatives X et Y présentes chez chaque individus. Soit donc la série statistique à deux variables $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ définie par les couples de valeurs observés chez chaque individu, on définit la covariance entre X et Y ,

notée $Cov(X, Y)$ par

$$Cov(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

La covariance est une *généralisation* du principe de variance pour une série statistique bivariable. En effet,

$$Cov(X, X) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x}) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = V(X).$$

La variance est égale à la moyenne du carré des écarts des observation à la moyenne. La covariance est définie en faisant le produits des écarts de chaque variable à sa moyenne puis en prenant la moyenne de ce nombre.

Propriété :

$$Cov(X, Y) = \left(\frac{1}{n} \sum_{i=1}^n x_i y_i \right) - \bar{x} \bar{y}.$$

Exemple : Dans l'exemple numérique précédent on obtient la covariance suivante

$$\begin{aligned} Cov(X, Y) &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \\ &= \frac{1}{9} \left((0.9 - 3.24)(0.9 - 2.98) + \dots + (5.6 - 3.24)(4.9 - 2.98) \right) \\ Cov(X, Y) &= 0.8654. \end{aligned}$$

Interprétation :

La covariance nous renseigne sur le lien entre deux variables. Si deux variables ont tendance à évoluer ensemble, leur covariance est positive. Si elles ont tendance à évoluer inversement l'une de l'autre, leur covariance est négative.

Si deux variables sont indépendantes, alors leur covariance sera nulle mais l'inverse n'est pas vrai, une covariance nulle n'est pas synonyme d'indépendance. De plus, la covariance **n'est pas une mesure standardisé**, c'est à dire

qu'elle dépend de l'unité dans laquelle sont exprimées les données. En ce sens il est impossible de s'en servir comme critère pour évaluer l'intensité du lien entre deux variables.

Pour évaluer un tel lien on va avoir recours au **coefficient de corrélation linéaire**.

Définition 16 : Soit un échantillon de n individus. Soit deux variables quantitatives X et Y présentes chez chaque individu. Soit donc la série statistique à deux variables $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ définie par les couples de valeurs observés chez chaque individu et $Cov(X, Y)$ la covariance entre les variables X et Y on définit le coefficient de corrélation linéaire, noté $r(X, Y)$, par

$$r(X, Y) = \frac{Cov(X, Y)}{\sigma(X) \sigma(Y)},$$

où $\sigma(X)$ et $\sigma(Y)$ sont les écart-types des variables X et Y respectivement.

Le coefficient de corrélation linéaire est donc le rapport entre la covariance et le produit des écart-types.

Propriété :

$$-1 \leq r(X, Y) \leq 1.$$

Exemple : Dans notre exemple, on obtient le coefficient de corrélation suivant :

$$r(X, Y) = \frac{Cov(X, Y)}{\sigma(X) \sigma(Y)} = \frac{0.8654}{1.551 \times 1.642} = 0.339.$$

Interprétation :

Le coefficient de corrélation linéaire nous permet d'avoir une meilleure idée du lien entre deux variables. Tout comme la variance, il évolue positivement si les deux variables évoluent ensemble et négativement si les deux variables évoluent de manière opposée.

Plus le coefficient de corrélation linéaire est proche de 1 ou de -1 plus la corrélation linéaire entre les variables est forte. Si le coefficient de corrélation linéaire est proche de 0, alors le lien entre les deux variables est faible.

Dans l'exemple, le coefficient de corrélation linéaire est de 0.339. Il est positif mais n'est pas particulièrement proche de 1. Le lien entre nos variables n'est donc pas particulièrement fort.

Il convient d'ajouter quelques précisions quand à l'interprétation du coefficient de corrélation linéaire.

- Le coefficient de corrélation *linéaire* mesure un lien *linéaire* entre deux variables. C'est à dire est-ce que ce lien peut prendre la forme d'une *droite*. En conséquence, un coefficient de corrélation linéaire nul ne veut pas nécessairement dire qu'il n'existe pas de liens entre deux variables. Il est possible qu'un lien existe mais qu'il ne soit pas linéaire.
- Un coefficient de corrélation linéaire élevé *n'est pas une preuve* de l'existence d'une forte dépendance entre deux variables. En effet il se peut qu'une variable supplémentaire influe sur ses deux variables, et donc force une corrélation mécanique entre elles.
- Il faut garder en tête que corrélation ne veut pas dire causalité. Nous reviendrons sur ce point un peu plus tard.

4.2.3 Régression linéaire

Maintenant que nous avons vu comment répondre à la question “ y'a-t-il un lien entre les variables X et Y ? ” nous aimerions pouvoir quantifier ce lien entre les deux variables. En d'autres termes on aimerait pouvoir prédire les valeurs de Y en utilisant les valeurs de X . On considérera alors que Y est la variable *expliquée* et X est la variable *explicative*.

On cherche donc à expliquer un lien fonctionnel entre X et Y . Mathématiquement, on cherche donc une fonction f telle que

$$Y = f(X).$$

Seulement voilà, quelle fonction va-t-on choisir ? Et comment ?


Dans ce cours on va se limiter à un certain type de fonction, les fonctions affines. C'est à dire qu'on va chercher une fonction f qui aura la forme

$$f(x) = a \times x + b.$$

Ceci est l'équation d'une droite. D'où le terme de régression *linéaire*. Il existe d'autre types de régressions mais ça sera pour les prochaines années.

On s'est donc restreint à chercher un certain type de fonction, celles qui sont linéaires. Mais le problème reste entier ! Parmi l'infinité de fonction affines, laquelle choisir ?

Reprenons notre nuage de point du début. On peut tracer autant de droites que l'on veut




L'idée est de trouver parmi toutes les droites possibles dont nous avons tracer que quelques une celle qui est la plus "proche" de tous les points du nuage. Comment définir cette proximité ?

On souhaite la droite qui soit globalement la moins distante de tous les points. Mathématiquement on va devoir donc définir cette "distance". Dès lors, "proche" signifiera "qui a une distance faible". La meilleure droite possible sera celle qui aura la distance la plus faible.

On avance, mais on a surtout découvert un nouveau problème ! Comment définir cette distance ?

Le but de cette droite est d'expliquer Y par X , c'est à dire d'exprimer Y en fonction de X . Pour chaque valeur de X la droite va donc prédire une valeur de Y . Pour les observations que nous avons on peut donc mesurer la distance entre le Y observé et le Y prédit. Prenons une des multiples droite et regardons ça.



Les lignes pointillés bleues sont donc les distances de chaque point avec la droite. Une première idée serait de faire la somme de toutes ces distances entre l'estimation de la droite et l'observation. Cependant ces distances peuvent être positives ou négatives. Ce qui veut dire qu'une forte distance positive annulerait une forte distance négative. Donc une erreur en compenserait une autre ! Nous ce qu'on veut c'est un minimum d'erreur. On a alors deux solutions :

- Faire la somme des valeurs absolues,
- Faire la somme des carrés.

Par convention on préfère la somme des carrés car cela facilite beaucoup les calculs. On a donc notre critère de distance de la droite par rapport aux points du nuage ! Cette distance sera la somme des carrés de la différence entre la valeur estimée de Y et la valeur observée de Y . Comme on cherche à minimiser la distance, pour être au plus proche, on va chercher la somme des carrés la plus faible. D'où le nom de cette méthode de régression : **la méthode des moindres carrés**.

Formalisons maintenant un peu tout cela. Soit un échantillon de taille n , et deux variables quantitatives X et Y . Soit donc la série statistique à deux variables $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ définie par les couples de valeurs observés chez chaque individu.

On considère une droite de régression linéaire de la forme $f(x) = a \times x + b$. Pour chaque valeur observée x_i on associe une valeur $\hat{y}_i = f(x_i)$. C'est la

valeur de Y prédite par la droite pour l'individu i compte tenu de sa valeur x_i . La valeur

$$d(i) = y_i - \hat{y}_i, \quad \forall i \in [1 : n],$$

représente l'écart entre la valeur prédite et la valeur observée pour chaque individu.

Enfin on définit la distance entre la droite de régression et l'ensemble des points par

$$\begin{aligned} D(a, b) &= \sum_{i=1}^n d(i)^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \\ &= \sum_{i=1}^n (y_i - (a \times x_i + b))^2. \end{aligned}$$

Cette distance $D(a, b)$ dépend donc des paramètres de la régression (a , le coefficient directeur de la droite de régression et b , son ordonnée à l'origine). Notre objectif maintenant, pour trouver la meilleure droite, est de résoudre ce problème :

$$\min_{\{a, b\}} D(a, b),$$

c'est-à-dire de trouver les valeurs de a et de b qui minimise la distance de la droite aux points.

Résultat :


La meilleure droite, c'est à dire celle qui minimise la distance $D(a, b)$, est appelée droite de régression linéaire et a pour équation $y = \hat{a} \times x + \hat{b}$ avec

$$\begin{aligned} \hat{a} &= \frac{Cov(X, Y)}{V(X)}, \\ \hat{b} &= \bar{y} - \hat{a} \times \bar{x}. \end{aligned}$$

Dans notre exemple la droite de régression aurait donc pour paramètres :

$$\begin{aligned} \hat{a} &= \frac{Cov(X, Y)}{V(X)} = \frac{0.8654}{2.4077} = 0.3954, \\ \hat{b} &= \bar{y} - \hat{a} \times \bar{x} = 2.9777 - 0.3954 \times 3.2444 = 1.6948. \end{aligned}$$

On peut la tracer et observer que la droite passe par le point moyen G (c'est toujours le cas).



Preuve :

On cherche donc à minimiser la formule $D(a, b) = \sum_{i=1}^n (y_i - (a \times x_i + b))^2$ par rapport à a et b . On va donc annuler les dérivées partielles de $D(a, b)$.

$$\frac{\delta D(a, b)}{\delta a} = \sum_{i=1}^n 2(y_i - a x_i - b) \times (-x_i) = 0,$$

$$\Leftrightarrow -2 \sum_{i=1}^n (y_i - a x_i - b) x_i = 0,$$

$$\Leftrightarrow \sum_{i=1}^n (x_i y_i - a x_i^2 - x_i b) = 0,$$

$$\Leftrightarrow \sum_{i=1}^n x_i y_i - a \sum_{i=1}^n x_i^2 - b \sum_{i=1}^n x_i = 0,$$

$$\Leftrightarrow \sum_{i=1}^n x_i y_i = a \sum_{i=1}^n x_i^2 + b \sum_{i=1}^n x_i,$$

$$\begin{aligned}
\frac{\delta D(a, b)}{\delta b} &= \sum_{i=1}^n 2(y_i - a x_i - b) = 0, \\
&\Leftrightarrow 2 \sum_{i=1}^n (y_i - a x_i - b) = 0, \\
&\Leftrightarrow \sum_{i=1}^n y_i - a \sum_{i=1}^n x_i - \sum_{i=1}^n b = 0, \\
&\Leftrightarrow \sum_{i=1}^n y_i = a \sum_{i=1}^n x_i + n b,
\end{aligned}$$

On a donc le système d'équations :

$$\sum_{i=1}^n x_i y_i = a \sum_{i=1}^n x_i^2 + b \sum_{i=1}^n x_i, \quad (1)$$

$$\sum_{i=1}^n y_i = a \sum_{i=1}^n x_i + n b, \quad (2)$$

Si on divise l'équation (2) par n on obtient

$$\begin{aligned}
\frac{1}{n} \sum_{i=1}^n y_i &= a \frac{1}{n} \sum_{i=1}^n x_i + b, \\
\bar{y} &= a \bar{x} + b.
\end{aligned}$$

Ce qui nous indique que la droite de régression passe par le point moyen $(\bar{y}, \bar{x})$. On peut donc en déduire la valeur de b :

$$b = \bar{y} - a \bar{x}.$$

En remplaçant b par son expression dans l'équation (1) on a

$$\begin{aligned}
\sum_{i=1}^n x_i y_i &= a \sum_{i=1}^n x_i^2 + (\bar{y} - a \bar{x}) \sum_{i=1}^n x_i, \\
\sum_{i=1}^n x_i y_i &= a \sum_{i=1}^n x_i^2 + \left(\frac{1}{n} \sum_{i=1}^n y_i - a \frac{1}{n} \sum_{i=1}^n x_i \right) \sum_{i=1}^n x_i, \\
\sum_{i=1}^n x_i y_i &= a \sum_{i=1}^n x_i^2 + \frac{1}{n} \sum_{i=1}^n y_i \sum_{i=1}^n x_i - a \frac{1}{n} \sum_{i=1}^n x_i \sum_{i=1}^n x_i,
\end{aligned}$$

En isolant a on obtient

$$\sum_{i=1}^n x_i y_i - \frac{1}{n} \sum_{i=1}^n y_i \sum_{i=1}^n x_i = a \left(\sum_{i=1}^n x_i^2 - \frac{1}{n} \sum_{i=1}^n x_i \sum_{i=1}^n x_i \right). \quad (3)$$

La partie à gauche du signe égal de l'équation (3) peut s'écrire

$$\begin{aligned} \sum_{i=1}^n x_i y_i - \frac{1}{n} \sum_{i=1}^n y_i \sum_{i=1}^n x_i &= n \left(\frac{1}{n} \sum_{i=1}^n x_i y_i - \frac{1}{n} \frac{1}{n} \sum_{i=1}^n y_i \sum_{i=1}^n x_i \right) \\ &= n \left(\frac{1}{n} \sum_{i=1}^n x_i y_i - \frac{1}{n} \sum_{i=1}^n y_i \frac{1}{n} \sum_{i=1}^n x_i \right) \\ &= n \left(\frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{y} \bar{x} \right) \\ &= n \times Cov(X, Y). \end{aligned}$$

La partie de droite de (3) s'écrit

$$\begin{aligned} a \left(\sum_{i=1}^n x_i^2 - \frac{1}{n} \sum_{i=1}^n x_i \sum_{i=1}^n x_i \right) &= n \times a \left(\frac{1}{n} \sum_{i=1}^n x_i^2 - \frac{1}{n} \frac{1}{n} \sum_{i=1}^n x_i \sum_{i=1}^n x_i \right) \\ &= n \times a \left(\frac{1}{n} \sum_{i=1}^n x_i^2 - \left(\frac{1}{n} \sum_{i=1}^n x_i \right)^2 \right) \\ &= n \times a \left(\frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 \right) \\ &= n \times a \times V(X). \end{aligned}$$

En réunissant ces deux résultats on a

$$\begin{aligned} n \times Cov(X, Y) &= n \times a \times V(X), \\ \Leftrightarrow a &= \frac{n \times Cov(X, Y)}{n \times V(X)}, \\ \Leftrightarrow a &= \frac{Cov(X, Y)}{V(X)}, \end{aligned}$$

ce qui conclut la preuve.

4.2.4 Qualité de la régression

Le coefficient de corrélation linéaire nous permet d'apprécier la corrélation linéaire entre deux variables. Mais il existe un autre indicateur nous permettant de mesurer l'intensité de la liaison entre les deux variables et d'ainsi mesurer la qualité de la régression. On appelle cet indicateur le **coefficient de détermination**. Cet indicateur général est également utilisé pour les régressions linéaires à plusieurs variables explicatives. On l'utilisera beaucoup au fil des années.

Le coefficient de détermination est obtenu en faisant une analyse de la variance de la variable expliquée Y .

Résidus et analyse de la variance :

Considérons la variable Y et ses observations y_i . Notre modèle de régression nous permet de prédire les valeurs de Y . Ces prédictions sont les valeurs $\hat{y}_i = \hat{a} \times x_i + \hat{b}$. Comme on peut l'observer sur notre exemple précédent, nos prédictions ne sont pas parfaites, $\hat{y}_i \neq y_i$. On a donc des erreurs que l'on appelle des **résidus**. Ces résidus, que l'on va noter e_i sont égaux à

$$e_i = y_i - \hat{y}_i, \forall i \in [1 : n].$$

Par définition des résidus on a :

$$\sum_{i=1}^n e_i = 0.$$

En effet car

$$\begin{aligned} \sum_{i=1}^n e_i &= \sum_{i=1}^n (y_i - \hat{y}_i) = \sum_{i=1}^n (y_i - (\hat{a} x_i + \hat{b})) \\ &= \sum_{i=1}^n y_i - \hat{a} \sum_{i=1}^n x_i - \sum_{i=1}^n \hat{b} = n \bar{y} - \hat{a} n \bar{x} - n \hat{b} \\ &= n \bar{y} - \hat{a} n \bar{x} - n (\bar{y} - \hat{a} \bar{x}) = 0. \end{aligned}$$

Idéalement on souhaite que notre modèle ait des résidus les plus petits possible. Par définition dans le cas de la régression linéaire simple on a vu que leur somme était nulle car les résidus positifs compensent les résidus négatifs.

Intéressons nous donc à la somme des carrés des résidus.

On note SCR la **Somme des Carrés des Résidus** d'une régression :

$$SCR = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2,$$

cette somme est nulle uniquement si notre prédiction est parfaite. Mais dans la très grande majorité des cas nos prédictions ne sera pas parfaite. Comment mesurer alors ce qu'est une bonne prédiction ? Pour répondre à cette question nous allons décomposer la variance de Y . Pourquoi s'intéresser à la variance ? La variance mesure la dispersion des valeurs observées de Y par rapport à la moyenne $\bar{y}$. C'est cette dispersion, cette variabilité qu'on cherche à expliquer. C'est dans cette variabilité que se trouve l'information. Notre modèle se résume en effet à expliquer la variation des valeurs observées de Y autour de la moyenne grâce aux valeurs observées des X .

Considérons la quantité suivante, que l'on appelle **Somme des Carrés Totaux** (SCT),

$$SCT = \sum_{i=1}^n (y_i - \bar{y})^2.$$

Notons que $SCT = n \times Var(Y)$. Décomposons la SCT et faisons apparaître les prédictions $\hat{y}_i$.

$$\begin{aligned} SCT &= \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (y_i - \hat{y}_i + \hat{y}_i - \bar{y})^2 \\ &= \sum_{i=1}^n \left[(y_i - \hat{y}_i)^2 + (\hat{y}_i - \bar{y})^2 + 2 \times (y_i - \hat{y}_i)(\hat{y}_i - \bar{y}) \right] \\ &= \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n 2 \times (y_i - \hat{y}_i)(\hat{y}_i - \bar{y}) \end{aligned}$$

Nous allons d'abord prouver que le dernier terme de cette équation est nul.

On sait que

$$\begin{aligned}\hat{y}_i &= \hat{a} x_i + \hat{b}, \\ \bar{y} &= \hat{a} \bar{x} + \hat{b}, \\ \hat{a} &= \frac{Cov(X, Y)}{V(X)} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}.\end{aligned}$$

En conséquence

$$\begin{aligned}\hat{y}_i - \bar{y} &= \hat{a}(x_i - \bar{x}), \text{ et} \\ y_i - \hat{y}_i &= y_i + \bar{y} - \bar{y} - \hat{y}_i = (y_i - \bar{y}) - (\hat{y}_i - \bar{y}) = (y_i - \bar{y}) - \hat{a}(x_i - \bar{x}).\end{aligned}$$

On a donc

$$\begin{aligned}\sum_{i=1}^n 2 \times (y_i - \hat{y}_i)(\hat{y}_i - \bar{y}) &= \sum_{i=1}^n 2 \times \hat{a}(x_i - \bar{x})[(y_i - \bar{y}) - \hat{a}(x_i - \bar{x})] \\ &= 2\hat{a} \sum_{i=1}^n (x_i - \bar{x})[(y_i - \bar{y}) - \hat{a}(x_i - \bar{x})] \\ &= 2\hat{a} \sum_{i=1}^n \left[(x_i - \bar{x})(y_i - \bar{y}) - \hat{a}(x_i - \bar{x})^2 \right] \\ &= 2\hat{a} \left(\sum_{i=1}^n \left[(x_i - \bar{x})(y_i - \bar{y}) \right] - \hat{a} \sum_{i=1}^n \left[(x_i - \bar{x})^2 \right] \right) \\ &= 2\hat{a} \left(\sum_{i=1}^n \left[(x_i - \bar{x})(y_i - \bar{y}) \right] - \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n \left[(x_i - \bar{x})^2 \right] \right) \\ &= 2\hat{a} \left(\sum_{i=1}^n \left[(x_i - \bar{x})(y_i - \bar{y}) \right] - \sum_{i=1}^n \left[(x_i - \bar{x})(y_i - \bar{y}) \right] \right) \\ &= 0.\end{aligned}$$

On obtient donc alors

$$SCT = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2.$$

On reconnaît dans cette expression la SCR (somme des carrés des résidus) et une autre quantité que l'on va appeler la **Somme des Carrés Expliqués**,

SCE :

$$SCE = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2.$$

La SCT se décompose alors ainsi :

$$SCT = SCE + SCR.$$

On a ainsi une décomposition de la variance de Y puisque $V(Y) = \frac{1}{n}SCT$.
Comment est-ce qu'on interprète ces quantités ?

- SCT est la somme des carrés totaux : c'est la variabilité totale de Y .
- SCE est la somme des carrés expliqués. La somme du carré des écarts entre la prédiction et la moyenne. Elle représente donc la variabilité qui est expliquée par notre modèle. Les variations de Y expliquée par X .
- SCR est la somme des carrés des résidus. C'est l'écart entre les valeurs observées et les valeurs prédites. Elle représente donc la variabilité qui n'est pas expliquée par notre modèle.

On peut distinguer deux situations extrêmes qui peuvent survenir :

- Si $SCR = 0$ (et donc $SCT = SCE$) alors l'ensemble de la variabilité de Y est expliquée. Notre modèle est offre donc une prédiction parfaite. La droite de régression passe par tous les nuages du point.
- Si $SCE = 0$ (et donc $SCT = SCR$) alors X n'apporte aucune information. Aucune part de la variabilité n'est expliquée par le modèle. Ainsi la meilleure prédiction possible que l'on peut faire de Y est $\hat{y} = \bar{y}$, c'est à dire prédire systématiquement la moyenne des observations.

Coefficient de détermination :

A partir de cette analyse de la variance de Y nous pouvons à présent construire un indicateur qui permet de mesurer la qualité de la régression.

Définition 17 : On définit le coefficient de détermination, noté R^2 , par

$$R^2 = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT},$$

ou en d'autre termes

$$R^2 = \frac{\text{Variabilité expliquée}}{\text{Variabilité totale}} = 1 - \frac{\text{Variabilité résiduelle}}{\text{Variabilité totale}},$$

ou encore

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}.$$

Cet indicateur nous donne la proportion de la variance de Y qui est expliquée par le modèle.

- Plus la valeur du R^2 sera proche de 1, plus on considèrera le modèle performant. Le modèle permet d'utiliser les valeurs de X pour prédire avec précision les valeurs de Y .
- Si le R^2 est proche de 0, alors on considèrera le modèle comme peu performant.

Propriétés :

1. $R^2 = \frac{V(\hat{Y})}{V(Y)}$.
2. Dans le cas de la régression linéaire simple (c'est à dire avec une seule variable explicative comme ci) et *uniquement dans ce cas*, on a également la relation suivante

$$R^2 = \frac{Cov(X, Y)^2}{Var(X)Var(Y)}.$$

Ce qui correspond au carré du coefficient de corrélation linéaire entre X et Y .

$$R^2 = r(X, y)^2.$$

C'est de là que vient principalement la notation R^2 .

En conséquence, dans le cas d'une régression linéaire simple, le coefficient de détermination R^2 ne peut pas être négatif. En revanche il peut l'être dans le cas de régressions linéaires multiples.

Preuves :

Pour la propriété 1. On a

$$\begin{aligned}\frac{V(\hat{Y})}{V(Y)} &= \frac{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2} \\ &= \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \\ &= R^2.\end{aligned}$$

Pour la propriété 2. On sait que $\hat{y}_i = \hat{a} x_i + \hat{b}$ et donc par les propriétés de la variance que $V(\hat{Y}) = V(\hat{a} X + \hat{b}) = \hat{a}^2 V(X)$. Par ailleurs, par définition on a $\hat{a} = \frac{Cov(X, Y)}{V(X)}$. On en déduit donc

$$\begin{aligned}V(\hat{Y}) &= \hat{a}^2 V(X) = \left(\frac{Cov(X, Y)}{V(X)} \right)^2 \times V(X) \\ &= \frac{Cov(X, Y)^2}{V(X)}.\end{aligned}$$

En utilisant la propriété 1 on a alors

$$R^2 = \frac{V(\hat{Y})}{V(Y)} = \frac{Cov(X, Y)^2}{V(X) V(Y)}.$$

Exemple :

Dans le cadre de notre exemple nous pouvons calculer le coefficient de détermination R^2 . On a

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = \frac{3.0114}{24.2946} = 0.1239.$$

On peut donc en conclure que la variable X explique mal la variable Y .

4.3 Causalité et corrélation : observations, faits et théories

Comme je l'ai signalé plus tôt, il est important de garder en tête que la corrélation et la causalité ne sont pas synonymes. Ce n'est pas parce que deux grandeurs sont corrélées que l'une d'entre elle cause nécessairement l'autre.

C'est pour cela que l'expertise joue un grand rôle dans la pratique des statistiques. Nous ne nous intéressons pas à n'importe quels couples ou groupes de variables. Les données que nous décidons de recueillir, les observations que nous faisons sont motivées par des théories. **Il n'existe pas de faits ni d'observations sans théorie.**

C'est parce que nous avons des théories sur le fonctionnement du monde que nous pouvons envisager d'observer certaines variables, certains phénomènes. C'est parce que nous avons des théories sur le fonctionnement du monde que nous sommes en mesure de procéder à ces observations. Observer nécessite des outils, des indicateurs et des concepts abstraits. Le taux d'investissement d'un pays la croissance de son PIB ne sont pas des faits purs (si tant est que cela existe). Ils ont du sens dans le cadre d'une construction théorique, celle de la science économique. Ils sont mesurés par des indicateurs qui sont des outils produits par ces théories.

Quelle est la différence fondamentale entre étudier le lien entre le taux d'investissement et la croissance du PIB d'une part et le lien entre la consommation de viande poulet et la quantité importée de pétrole par les USA d'autres part ? La différence est que la première étude se base sur une vision théorique du monde. Mathématiquement, la corrélation est plus forte pour le deuxième couple d'observation, mais aucune théorie ne permet d'expliquer un tel lien et même simplement de poser la question.

5 Indices

Dans ce chapitre nous verrons le calcul de différents indices. Nous allons distinguer deux types d'indices. Les indices élémentaires et les indices synthétiques.

Les indices élémentaires concernent des séries simples de valeurs comme le prix d'un produit ou la production d'une entreprise. Nous observons l'évolution d'une grandeur et constituons un indice à partir de celle-ci.

Les indices synthétiques concernent des séries complexes qui nécessitent d'agréger des valeurs hétérogènes. Un indice de prix par exemple nécessite de s'intéresser à l'évolution des prix de plusieurs produits.

Nous commencerons ce chapitre par les indices élémentaires.

5.1 Indices élémentaires

Considérons le tableau suivant qui contient les données sur le prix en euros du kilogramme de fraises et le SMIC brut horaire entre 2001 et 2013 :

Année	Prix de vente fraises	SMIC horaire brut
2001	6,55	6,53
2002	7,21	6,75
2003	7,92	7,01
2004	7,40	7,40
2005	7,84	7,82
2006	7,93	8,15
2007	7,93	8,36
2008	8,53	8,61
2009	8,28	8,77
2010	9,32	8,86
2011	9,51	9,02
2012	9,84	9,31
2013	9,69	9,43

On peut observer que le prix de vente de fraises a globalement augmenté entre 2013 et 2001. Si l'on souhaite quantifier cette augmentation on peut simplement faire le rapport entre le prix des fraises en 2013 et le prix des fraises en 2001

$$I_{2013/2001}(fraises) = \frac{9.69}{6.55} = 1.4793.$$

Cette valeur nous indique que le prix des fraises en 2013 était 1.4793 fois plus élevé qu'en 2001. Afin d'avoir cette information en pourcentage nous avons juste à multiplier cet indice par 100. On a alors que le prix des fraises en 2013 équivaut à 147.93% du prix des fraises en 2001.

En utilisant les données du tableau on peut aussi comparer l'évolution du prix des fraises et l'évolution du SMIC horaire. Entre 2001 et 2013 pour le SMIC horaire brut on a

$$I_{2013/2001}(SMIC) = \frac{9.43}{6.53} = 1.4441.$$

Le SMIC horaire brut a donc augmenté moins vite que le prix des fraises ($\times 1.4441$ pour le SMIC contre $\times 1.4793$ pour les fraises).

Les rapports que nous avons calculer ci-dessus sont des **indices élémentaires**.

Définition 18 : Soit une grandeur x prenant la valeur x_0 à la date 0 et la valeur x_t à la date t . On appelle indice élémentaire $I_{t/0}(x)$ le nombre suivant :

$$I_{t/0}(x) = \frac{x_t}{x_0}.$$

On exprime fréquemment ces indices en terme de pourcentage :

$$i_{t/0}(x) = \frac{x_t}{x_0} \times 100.$$

La date 0 correspond à la **date de référence** ou **de base**, la date t est la **date courante**. Si l'indice est exprimé en pourcentage on dit qu'il est en base 100 à la date de référence. C'est à dire que la valeur de l'indice vaut 100 pour la date de référence : $I_{0/0}(x) = 100$. S'il n'est pas en pourcentage, l'indice vaut 1 en date 0.

Taux de variation :

L'indice élémentaire nous donne une valeur qui se réfère à la valeur de base. Dans notre exemple, entre 2013 et 2001 les fraises sont passés d'un indice de 1 en 2001 à un indice de 1.4793 en 2013. De combien de pourcentage a été l'augmentation ? Répondre à cette question revient à calculer un taux de variation.

Nous sommes passés d'une valeur de 1 en 2001 à une valeur de 1.4793 en 2013. La différence est donc de

$$1.4793 - 1 = 0.4793$$

ce qui, en pourcentage donne 47.93%. Le **taux de variation** $TV_{t/0}(x)$ d'une grandeur x entre la date 0 et la date t se calcule donc ainsi

$$\begin{aligned} TV_{t/0}(x) &= (I_{t/0}(x) - I_{0/0}(x)) \times 100 \\ &= \left(\frac{x_t}{x_0} - \frac{x_0}{x_0} \right) \times 100 \\ TV_{t/0}(x) &= \frac{x_t - x_0}{x_0} \times 100. \end{aligned}$$

En d'autres termes le taux de variation est égal à la valeur courante moins la valeur de référence divisé par la valeur de référence. On prend la différence entre la valeur qui courante et celle de référence qu'on rapporte à la valeur de référence afin de l'avoir en proportion de cette dernière.

5.1.1 Propriétés de l'indice élémentaire

- **Circularité** : $I_{t/0}(x) = I_{t/t'}(x) \times I_{t'/0}(x)$, $\forall t' \in [0 : t]$. On peut comparer les valeurs aux date t et 0 en comparant les valeurs aux dates t et t' d'une part et t' et 0 d'autre part.
- **Réversibilité** : $I_{t/0}(x) = \frac{1}{I_{0/t}(x)}$. L'indice qui compare la grandeur x à la date t et à la date 0 en prenant la date 0 comme référence est l'inverse de l'indice qui compare la grandeur x à la date t et à la date 0 en prenant la date t comme référence.

5.2 Indices synthétiques

Quand on étudie l'économie on est le plus souvent confronté à la nécessité de travailler avec des indicateurs qui agrègent et synthétisent plusieurs grandeurs. Prenons par exemple le PIB : c'est un indicateur qui agrège la valeur économique de tous les biens et services produits. Pour le calculer on va prendre la quantité produite des différents bien et services et faire le produit avec leur valeur économique (le prix le plus souvent mais pas que). Cet indicateur synthétique est ce qu'on appelle un *indicateur de valeur* (il associe une valeur à la production globale). On verra également les *indices de prix* et les *indices de quantités*.

5.2.1 Indice de valeurs, de prix et de quantités

Considérons une grandeur x composée de k éléments $x^1, x^2, \dots, x^k$. Soit $x_0, x_1, \dots, x_t$ les valeurs de cette grandeur de la date 0 à la date t . Ainsi si x est le PIB, les éléments $x^1, x^2, \dots, x^k$ représentent les k biens et services pris en compte dans son calcul. On note également

p_0^i et p_t^i , le prix, respectivement aux dates 0 et t , de l'élément x^i , $\forall i \in [1 : k]$,
 q_0^i et q_t^i , la quantité, respectivement aux dates 0 et t , de l'élément x^i , $\forall i \in [1 : k]$,
 $x_j^i = p_j^i q_j^i$, $\forall i \in [1 : k]$, $\forall j \in [0 : t]$.

Définition 19 : Etant donné la grandeur x composée de k éléments $x^1, x^2, \dots, x^k$, on définit l'**indice de valeur** $I_{t/0}^V(x)$ par

$$I_{t/0}^V(x) = \frac{x_t}{x_0} = \frac{\sum_{i=1}^k x_t^i}{\sum_{i=1}^k x_0^i} = \frac{\sum_{i=1}^k p_t^i q_t^i}{\sum_{i=1}^k p_0^i q_0^i}.$$

Exemple :

Considérons le tableau suivant d'une économie fictive qui produit des fraises et de framboises. Nous avons les prix (pour 1kg) et les quantités pour les années 2001 à 2013.

Année	Prix fraises	Quantité fraises	Prix Framboises	Quantité framboises
2001	6,55	5	4.32	2
2002	7,21	5	4.65	3
2003	7,92	6	4.83	5
2004	7,40	7	5.02	6
2005	7,84	8	4.95	4
2006	7,93	8	5.08	3
2007	7,93	9	5.08	3
2008	8,53	10	4.95	2
2009	8,28	9	4.42	4
2010	9,32	9	3.80	5
2011	9,51	8	3.65	8
2012	9,84	6	3.55	9
2013	9,69	5	4.2	8

En prenant comme date de référence l'année 2001 calculer l'indice de la production de cette économie à l'année 2013. On a

$$\begin{aligned}
 I_{t/0}^V(x) &= \frac{\sum_{i=1}^k p_t^i q_t^i}{\sum_{i=1}^k p_0^i q_0^i} \\
 &= \frac{9.69 \times 5 + 4.2 \times 8}{6.55 \times 5 + 4.32 \times 2} \\
 &= \frac{82.05}{41.39} = 1.982,
 \end{aligned}$$

soit en pourcentage 198.2%. Entre 2001 et 2013, la valeur de la production de cette économie a presque doublée.

En présence d'un indice de valeur comme définit ci-dessus (tel que le PIB) il faut garder en tête qu'une hausse (resp. une baisse) observée dans l'indice de valeur peut être due à une hausse (resp. une baisse) des prix uniquement, des quantités, des quantités et des prix ou à une hausse (resp. une baisse) des prix qui compensent une baisse (resp. une hausse) des quantités. Ou toute autre combinaison.

Afin de pouvoir tirer plus d'information de ces indices de valeurs on peut supposer que l'une des deux variables (prix ou quantité) est fixe afin de

neutraliser les effets de cette variable sur l'indice et se focaliser sur l'autre variable. On a alors deux types d'indices, les **indices de prix** et les **indices de quantités**.

- On calcule l'indice des prix en neutralisant l'influence des quantités, c'est à dire en considérant comme fixes les quantités sur la période considérée.
- On calcule l'indice des quantités en neutralisant l'influence des prix, c'est à dire en considérant comme fixes les prix sur la période considérée.

Il existe plusieurs manières de calculer ces indices de prix et de quantités.

5.2.2 Indices de Laspeyres

Indice des prix de Laspeyres

Etant un indice des prix, l'indice des prix de Laspeyres considère comme constantes les quantités afin de se concentrer sur la variation en prix. Les quantités considérées constantes sont les quantités de la date de référence. Soit une grandeur x , l'indice des prix de Laspeyres entre la date t et la date 0, noté $L_{t/0}^p(x)$ est défini ainsi

$$L_{t/0}^p(x) = \frac{\sum_{i=1}^k p_t^i q_0^i}{\sum_{i=1}^k p_0^i q_0^i}.$$

C'est donc le rapport la valeur courante mesurée comme le produit du prix avec les quantités de la date de référence et la valeur de la date de référence.

Indice des quantités de Laspeyres

L'indice des quantités de Laspeyres s'obtient en considérant comme constants les prix. Les prix considérés comme constants sont les prix de la date de référence. Soit une grandeur x , l'indice des quantités de Laspeyres entre la date t et la date 0, noté $L_{t/0}^q(x)$ est défini ainsi

$$L_{t/0}^q(x) = \frac{\sum_{i=1}^k p_0^i q_t^i}{\sum_{i=1}^k p_0^i q_0^i}.$$

C'est donc le rapport la valeur courante mesurée comme le produit des quantités de la date de référence avec le prix courant et la valeur de la date de référence.

Dans les deux indices de Laspeyres, le dénominateur reste toujours la valeur à la date de référence. Les indices de Paasche inverse ce principe.

5.2.3 Indices de Paasche

Indice des prix de Paasche

L'indice des prix de Paasche considère donc comme constantes les quantités. Mais ces quantités constantes sont celles de la date *courante*. Soit une grandeur x , l'indice des prix de Paasche entre la date t et la date 0, noté $P_{t/0}^p(x)$ est défini ainsi

$$P_{t/0}^p(x) = \frac{\sum_{i=1}^k p_t^i q_t^i}{\sum_{i=1}^k p_0^i q_t^i}.$$

Là où l'indice de Laspeyres modifie le numérateur, l'indice Paasche modifie le dénominateur. C'est donc le rapport entre la valeur à la date courante et la valeur correspondant à la quantité de la date courante aux prix de la date de référence.

Indice des quantités de Paasche

Enfin, l'indice des quantités de Paasche considère comme constants les prix. Ces prix constants sont ceux de l'année de référence. Soit une grandeur x , l'indice des quantités de Paasche entre la date t et la date 0, noté $P_{t/0}^q(x)$ est défini ainsi

$$P_{t/0}^q(x) = \frac{\sum_{i=1}^k p_t^i q_t^i}{\sum_{i=1}^k p_t^i q_0^i}.$$

C'est donc le rapport entre la valeur à la date courante et la valeur correspondant à la quantité de la date de référence aux prix courants.

5.2.4 Indices de Fisher

Les indices de Paasche et Laspeyres donnent tout deux des résultats différents, mais aucun des deux n'est "meilleur" ou "supérieur" à l'autre. Ainsi, les indices de Fisher sont une combinaison des indices de Paasche et Laspeyres qui donnent une valeur se situant entre les deux.

Soit une grandeur x , l'indice des prix de Fisher entre la date t et la date 0, noté $F_{t/0}^p(x)$ est défini ainsi

$$F_{t/0}^p(x) = \sqrt{L_{t/0}^p(x) P_{t/0}^p(x)}.$$

L'indice des quantités de Fisher entre la date t et la date 0, noté $F_{t/0}^q(x)$ est quant à lui défini ainsi

$$F_{t/0}^q(x) = \sqrt{L_{t/0}^q(x) P_{t/0}^q(x)}.$$

Exemple :

Reprenons le tableau précédent de notre économie fictive.

Année	Prix fraises	Quantité fraises	Prix Framboises	Quantité framboises
2001	6,55	5	4.32	2
2002	7,21	5	4.65	3
2003	7,92	6	4.83	5
2004	7,40	7	5.02	6
2005	7,84	8	4.95	4
2006	7,93	8	5.08	3
2007	7,93	9	5.08	3
2008	8,53	10	4.95	2
2009	8,28	9	4.42	4
2010	9,32	9	3.80	5
2011	9,51	8	3.65	8
2012	9,84	6	3.55	9
2013	9,69	5	4.2	8

Nous avons vu dans l'exemple précédent que la valeur de la production de cette économie a augmenté de 98.2% (l'indice $I_{t/0}^V(x)$ est de 198.2%) entre 2001 et 2013. Intéressons nous à l'augmentation globale des prix en calculant

les trois indices de prix différents. On a

$$\begin{aligned}
 L_{t/0}^p(x) &= \frac{\sum_{i=1}^k p_t^i q_0^i}{\sum_{i=1}^k p_0^i q_0^i} = \frac{9.69 \times 5 + 4.2 \times 2}{6.55 \times 5 + 4.32 \times 2} = \frac{56.85}{41.39} = 1.373, \\
 P_{t/0}^p(x) &= \frac{\sum_{i=1}^k p_t^i q_t^i}{\sum_{i=1}^k p_0^i q_t^i} = \frac{9.69 \times 5 + 4.2 \times 8}{6.55 \times 5 + 4.32 \times 8} = \frac{82.05}{67.31} = 1.219, \\
 F_{t/0}^p(x) &= \sqrt{L_{t/0}^p(x) P_{t/0}^p(x)} = 1.293.
 \end{aligned}$$

Selon l'indice de Laspeyres, les prix ont globalement augmentés de 37.3%. Selon l'indice de Paasche c'est 21.9%. L'indice de Fisher donne donc une augmentation de 29.3%.

Pour les quantités on a :

$$\begin{aligned}
 L_{t/0}^q(x) &= \frac{\sum_{i=1}^k p_0^i q_t^i}{\sum_{i=1}^k p_0^i q_0^i} = \frac{6.55 \times 5 + 4.32 \times 8}{6.55 \times 5 + 4.32 \times 2} = \frac{67.31}{41.39} = 1.626, \\
 P_{t/0}^q(x) &= \frac{\sum_{i=1}^k p_t^i q_t^i}{\sum_{i=1}^k p_t^i q_0^i} = \frac{9.69 \times 5 + 4.2 \times 8}{9.69 \times 5 + 4.2 \times 2} = \frac{82.05}{56.85} = 1.443, \\
 F_{t/0}^q(x) &= \sqrt{L_{t/0}^q(x) P_{t/0}^q(x)} = 1.531.
 \end{aligned}$$

En parallèle donc les quantités ont augmenté de 62.6% selon l'indice de Laspeyres, 44.3% selon celui de Paasche et 53.1% selon l'indice de Fisher.

5.2.5 Propriétés

Circularité : Les indices de Laspeyres, Paasche et Fisher ne vérifient pas la propriété de circularité.

$$\begin{aligned} L_{t/0}(x) &\neq L_{t/t'}(x) \times L_{t'/0}(x), \quad \forall t' \in [0 : t] \\ P_{t/0}(x) &\neq P_{t/t'}(x) \times P_{t'/0}(x), \quad \forall t' \in [0 : t] \\ F_{t/0}(x) &\neq F_{t/t'}(x) \times F_{t'/0}(x), \quad \forall t' \in [0 : t] \end{aligned}$$

Réversibilité : Les indices de Laspeyres et Paasche ne sont pas réversibles.

$$\begin{aligned} L_{t/0}(x) &\neq \frac{1}{L_{0/t}(x)}, \\ P_{t/0}(x) &\neq \frac{1}{P_{0/t}(x)}. \end{aligned}$$

En revanche :

$$\begin{aligned} L_{t/0}(x) &= \frac{1}{P_{0/t}(x)}, \\ P_{t/0}(x) &= \frac{1}{L_{0/t}(x)}. \end{aligned}$$

L'indice de Fisher est quand à lui réversible

$$F_{t/0}(x) = \frac{1}{F_{0/t}(x)}$$

Reconstitution de l'indice de valeur.

L'indice de valeur est donné par

$$I_{t/0}^v(x) = \frac{\sum_{i=1}^k p_t^i q_t^i}{\sum_{i=1}^k p_0^i q_0^i}$$

ce qui peut se décomposer ainsi :

$$I_{t/0}^v(x) = \frac{\sum_{i=1}^k p_t^i q_t^i}{\sum_{i=1}^k p_t^i q_0^i} \times \frac{\sum_{i=1}^k p_t^i q_0^i}{\sum_{i=1}^k p_0^i q_0^i} = \frac{\sum_{i=1}^k p_t^i q_t^i}{\sum_{i=1}^k p_0^i q_t^i} \times \frac{\sum_{i=1}^k p_0^i q_t^i}{\sum_{i=1}^k p_0^i q_0^i}$$

ce qui équivaut à

$$I_{t/0}^v(x) = P_{t/0}^q(x) \times L_{t/0}^p(x) = P_{t/0}^p(x) \times L_{t/0}^q(x)$$

et donc

$$\begin{aligned} I_{t/0}^v(x) &= \sqrt{P_{t/0}^q(x) \times L_{t/0}^p(x) \times P_{t/0}^p(x) \times L_{t/0}^q(x)} \\ I_{t/0}^v(x) &= \sqrt{L_{t/0}^p(x) \times P_{t/0}^p(x)} \times \sqrt{P_{t/0}^q(x) \times L_{t/0}^q(x)} \\ I_{t/0}^v(x) &= F_{t/0}^p(x) \times F_{t/0}^q(x). \end{aligned}$$

L'indice de valeur peut donc être entendu comme le produit des indices de Fisher de prix et de quantité.

5.3 Hétérogénéité et qualité

Les indices que nous avons calculés précédemment concernent les prix et les quantités dans leur globalité. Cependant on peut vouloir s'intéresser à la composition de notre indice de valeur et l'évolution de cette composition. Notamment si nous sommes en présence de biens ou produits qui ont plusieurs variétés avec des qualités différentes.

Prenons un exemple concernant la production de vin. On a $n = 2$ types de vins produits. Les vins de consommation courante et les vins de qualité supérieure. Le tableau suivant contient pour chacune de ces deux catégories le prix de vente du (en par litre) et la quantité produite (en millions de litres). La valeur V donne la valeur de la production en euros (=prix $\times$ quantité).

Variété i :	Vins courants ($i = 1$)			Vins supérieurs ($i = 2$)		
Année t	Prix p_t^i	Quantité q_t^i	Valeur V_t^i	Prix p_t^i	Quantité q_t^i	Valeur V_t^i
2005	2	575	1150	3.5	210	735
2013	2.5	415	1037.5	3.8	348	1322.4

On peut calculer le prix moyen $\bar{p}_t$ du vin à l'année t ainsi

$$\bar{p}_t = \frac{\sum_{i=1}^2 p_t^i q_t^i}{\sum_{i=1}^2 q_t^i} = \frac{\sum_{i=1}^2 V_t^i}{\sum_{i=1}^2 q_t^i}.$$

On a alors $\bar{p}_{2005} = 2.40$ et $\bar{p}_{2013} = 3.09$. On peut calculer l'indice élémentaire de variation du prix moyen du vin.

$$I_{2013/2005}^{\bar{p}}(x) = \frac{\bar{p}_{2013}}{\bar{p}_{2005}} = 1.288.$$

On peut également calculer l'indice élémentaire de variation de la quantité globale (la somme des quantités produites des deux qualités de vins)

$$I_{2013/2005}^q(x) = \frac{q_{2013}}{q_{2005}} = \frac{763}{785} = 0.972.$$

Et enfin on peut calculer l'indice de variation de la valeur globale (la somme des valeurs des deux qualités de vins).

$$I_{2013/2005}^V(x) = \frac{V_{2013}}{V_{2005}} = \frac{2359.9}{1885} = 1.252.$$

De ces indices on tire les informations suivantes :

- La valeur de la production de vin a augmenté de 25.2% entre 2005 et 2013.
- Cette augmentation de la valeur se décompose en une diminution de 2.8% de la production globale et une augmentation de 28.8% du prix moyen.

Si l'on calcule les indices de Paasche et de Laspeyres pour les prix et quantités on obtient

	Laspeyres	Paasche
prix	1.186	1.152
quantité	1.086	1.056

Les indices de prix ici nous indique une inflation située entre 15.2% et 18.6% ce qui est très éloigné de ce que donne l'indice élémentaire (28.8%!). C'est du à un effet de structure. En effet les vins supérieurs représentent une part plus importante du total en 2013 par rapport à 2005. Comment analyser cet effet structurel ?

On sait que

$$I_{t/0}^V(x) = P_{t/0}^q(x) \times L_{t/0}^p(x) = P_{t/0}^p(x) \times L_{t/0}^q(x)$$

et que

$$\begin{aligned}
I_{t/0}^V(x) &= \frac{V_t}{V_0} = \frac{\sum_{i=1}^n p_t^i q_t^i}{\sum_{i=1}^n p_0^i q_0^i} = \frac{\sum_i^n q_t^i}{\sum_i^n q_0^i} \times \frac{\frac{\sum_{i=1}^n p_t^i q_t^i}{\sum_i^n q_t^i}}{\frac{\sum_{i=1}^n p_0^i q_0^i}{\sum_i^n q_0^i}} \\
&= I_{t/0}^q(x) \times I_{t/0}^p(x).
\end{aligned}$$

On a alors

$$I_{t/0}^V(x) = P_{t/0}^q(x) \times L_{t/0}^p(x) = P_{t/0}^p(x) \times L_{t/0}^q(x) = I_{t/0}^q(x) \times I_{t/0}^p(x),$$

ce qui nous permet d'obtenir les deux relations suivantes :

$$\begin{aligned}
S_t &= \frac{I_{t/0}^p(x)}{L_{t/0}^p(x)} = \frac{P_{t/0}^q(x)}{I_{t/0}^q(x)}, \\
S_t' &= \frac{I_{t/0}^p(x)}{P_{t/0}^p(x)} = \frac{L_{t/0}^q(x)}{I_{t/0}^q(x)}.
\end{aligned}$$

En détaillant on a

$$\begin{aligned}
S_t &= \frac{P_{t/0}^q(x)}{I_{t/0}^q(x)} = \frac{\sum_{i=1}^k p_t^i q_t^i}{\sum_{i=1}^k p_t^i q_0^i} \times \frac{\sum_i^n q_0^i}{\sum_i^n q_t^i} \\
&= \frac{\frac{\sum_{i=1}^n p_t^i q_t^i}{\sum_i^n q_t^i}}{\frac{\sum_{i=1}^n p_t^i q_0^i}{\sum_i^n q_0^i}},
\end{aligned}$$

et réciproquement

$$S_t' = \frac{\frac{\sum_{i=1}^n p_0^i q_t^i}{\sum_i^n q_t^i}}{\frac{\sum_{i=1}^n p_0^i q_0^i}{\sum_i^n q_0^i}},$$

Ces deux indicateurs, S_t et S_t' décrivent les changements dans la composition des vins vendus survenus entre la date de base et la date courante. La différence entre les deux indices est qu'on considère les prix courants dans l'indice S_t et les prix de base dans l'indice S_t' . Ces indices sont appelés **indices de structures**.

Dans notre exemple les indices sont égaux à

$$S_t = \frac{1.288}{1.186} = \frac{1.056}{0.972} = 1.086,$$

$$S_t' = \frac{1.288}{1.152} = \frac{1.086}{0.972} = 1.118.$$

En utilisant les définitions des indices S_t et S_t' et le fait que

$$I_{t/0}^V(x) = P_{t/0}^q(x) \times L_{t/0}^p(x) = P_{t/0}^p(x) \times L_{t/0}^q(x)$$

on obtient alors

$$I_{t/0}^V(x) = L_{t/0}^p(x) \times S_t \times I_{t/0}^q = P_{t/0}^p(x) \times S_t' \times I_{t/0}^q,$$

ce qui va nous permettre de décomposer la variation de valeur. Dans notre exemple on a

$$I_{t/0}^V(x) = 1.186 \times 1.086 \times 0.972 = 1.152 \times 1.118 \times 0.972 = 1.252.$$

On peut donc conclure que l'augmentation de 25.2% de la valeur de la production se décompose en

- une hausse du prix moyen qui se situe entre 15.2% et 18.6%,
- une augmentation de la qualité du vin entre 8.6% et 11.8% due à un effet de structure (l'augmentation relative de la part des vins de qualité supérieure),
- une baisse de la quantité vendue de 2.8%.