

Correction TD 1

EXERCICE 1 :

1. $x_i > 0, \forall i \in [1 : n]$. Ou encore $x_i > 0, \forall i, 1 < i < n$.
2. $\left(\sum_{i=1}^n x_i \right)^2$.
3. $\sum_{i=1}^n (x_i)^2$.
4. $\sum_{i=1}^n (x_i - \bar{x})^2$.
5. $x_i > 0, \forall i, 1 < i < n \Rightarrow \sum_{i=1}^n x_i > 0$.
6. $2x = 2 \Leftrightarrow x = 1$.

EXERCICE 2 :

1. La somme du produit des valeurs des valeurs y et x d'un individu j , pour j allant de 1 à p .
2. Il existe un i compris entre 1 et n tel que la valeur x de l'individu i est inférieure à 0.
3. La valeur x de l'individu i est strictement négative pour tout i compris entre 1 et n .
4. La valeur f de l'individu i est égale au rapport entre la valeur n de l'individu i et une valeur fixe n , et ce pour tout i compris entre 1 et n .
5. Si a est strictement inférieur à b alors la différence entre a et b est négative strictement.

EXERCICE 3 :

1. Qualitative ordinale.
2. Quantitative discrète
3. Qualitative ordinale.

- 4. Qualitative nominale.
- 5. Quantitative continue.
- 6. Quantitative continue.
- 7. Qualitative nominale.

Correction TD2

EXERCICE 1 : Le tableau suivant donne la répartition par groupe sanguins d'un échantillon de 50 personnes.

i	1	2	3	4
Groupe sanguin	A	B	AB	O
Effectifs n_i	21	n_2	6	8

1. Quel est le type de cette variable ? La variable "groupe sanguin d'un individu" est une variable qualitative nominale
2. Calculez l'effectif du groupe sanguin B. Sachant que la somme des effectifs de chaque modalité doit être égal à l'effectif total qui est ici de 50 on a :

$$\sum_{i=1}^n n_i = n \Leftrightarrow 21 + n_2 + 6 + 8 = 50 \Leftrightarrow n_2 = 50 - 21 - 6 - 8 = 15.$$

Il y a donc 15 individus dans l'échantillon qui ont un groupe sanguin de type B.

3. Calculez les fréquences de chaque groupe sanguin. La fréquence f_i de la modalité i est définie par

$$f_i = \frac{n_i}{n}.$$

On a donc $f_1 = \frac{21}{50} = 0.42$, $f_2 = \frac{15}{50} = 0.3$, $f_3 = \frac{6}{50} = 0.12$ et $f_4 = \frac{8}{50} = 0.16$.

4. Représentez avec les diagrammes appropriés la distribution de cette variable.

On peut représenter les fréquences avec un diagramme en barre ou un diagramme en secteur.

Diagramme en barres :





Diagramme en secteur :



5. Interprétez la fréquence d'un des groupes sanguins (faites une phrase exprimant ce que ce nombre représente). **On peut interpréter la fréquence de la modalité du groupe sanguin de type A de la manière suivante : Dans notre échantillon, 42% des individus présentent un groupe sanguin de type A.**

EXERCICE 2: A la suite d'un cours de statistiques, l'enseignant procède à un sondage sur la qualité de son cours. Il demande aux étudiants de répondre à la question "Ce cours était le meilleur cours de toute ma vie: d'accord ou pas d'accord ?" . Il obtient les résultats suivants:

i	Opinion	Effectif n_i
1	Pas du tout d'accord	26
2	Plutôt pas d'accord	54
3	Indifférent	20
4	Plutôt d'accord	67
5	Tout à fait d'accord	33

- Combien d'étudiants ont répondu à cette question ? **L'effectif total est égal à la somme des effectifs. Il y a donc $26 + 54 + 20 + 67 + 33 = 200$ personnes qui ont répondu à ce questionnaire.**
- Quel est le type de cette variable ? **La variable est une variable qualitative ordinale.**
- Calculez la fréquence pour chaque réponse. **La fréquence f_i de la modalité i est définie par**

$$f_i = \frac{n_i}{n}.$$

On a donc $f_1 = \frac{26}{200} = 0.13$, $f_2 = \frac{54}{200} = 0.27$, $f_3 = \frac{20}{200} = 0.10$, $f_4 = \frac{67}{200} = 0.335$ et $f_5 = \frac{33}{200} = 0.165$

4. Quelle est la proportion d'étudiants en désaccord avec l'affirmation ? La proportion en accord ? Les individus en désaccord sont ceux ayant répondu "Pas du tout d'accord" et "Plutôt pas d'accord". La proportion des individus en désaccord est donc de $0.13 + 0.27$ c'est à dire 40%. Les individus étant d'accord sont ceux ayant répondu "Plutôt d'accord" et "Tout à fait d'accord". La proportion est donc de $0.335 + 0.165 = 0.5$, soit 50%.
5. Quelle est la proportion ayant un avis extrême ? Les individus ayant un avis extrême sont ceux ayant répondu "Pas du tout d'accord" et "Tout à fait d'accord". La fréquence correspondante est donc la somme des fréquences de ces deux modalités soit $0.13 + 0.165 = 0.295$. 29.5% des individus ont donc un avis extrême.
6. Représentez graphiquement ces résultats. Pour plus de lisibilité sur les graphiques on va coder les modalités de la variable : Pas du tout d'accord= $D - -$, Plutôt pas d'accord= $D -$, Indifférent= I , Plutôt d'accord= $D +$, Tout à fait d'accord= $D + +$. On peut également les coder avec des chiffres si on le souhaite (ou tout autre système). Diagramme en barres :





Diagramme en secteur :



EXERCICE 3: Considérons le tableau (fictif) suivant représentant la répartition des revenus mensuels nets dans un échantillon.

i	1	2	3	4	5
Revenus	$[0; 1000[$	$[1000; 2000[$	$[2000; 3000[$	$[3000; 4000[$	$[4000; 6000[$
Effectifs n_i	130	232	342	23	12

1. Quelle est la variable étudiée et quel est son type ? La variable étudiée est le revenu mensuel nets. C'est une variable quantitative continue.
2. Calculez la fréquence pour chaque classe de revenu. La fréquence f_i est définie par

$$f_i = \frac{n_i}{n}.$$

Il nous faut donc savoir la taille de l'échantillon. Ici $n = 130 + 232 + 342 + 23 + 12 = 739$. Par conséquent on a $f_1 = \frac{130}{739} = 0.176$, $f_2 = \frac{232}{739} = 0.314$, $f_3 = \frac{342}{739} = 0.463$, $f_4 = \frac{23}{739} = 0.031$, $f_5 = \frac{12}{739} = 0.016$. On peut donc en conclure, par exemple, que 46.3% des individus de l'échantillon se situent dans la 3^e classe, c'est à dire qu'ils ont un revenu mensuel net compris entre 2000 et 3000 euros.


3. Représentez graphiquement la répartition des revenus. Afin de représenter cette répartition des revenus nous allons utiliser un histogramme. L'histogramme se construit en utilisant la densité. On définit la densité d_i par l'expression suivante

$$d_i = \frac{f_i}{e_{i+1} - e_i},$$

où e_i représente la borne inférieure de la classe i . Par exemple pour la première classe on a $d_1 = \frac{0.176}{1000 - 0} = 0.000176$.


i	1	2	3	4	5
Revenus	$[0; 1000[$	$[1000; 2000[$	$[2000; 3000[$	$[3000; 4000[$	$[4000; 6000[$
Effectifs n_i	130	232	342	23	12
Fréquences f_i	0.176	0.314	0.463	0.031	0.016
Densité d_i	0.000176	0.000314	0.000463	0.000031	0.000008

On obtient alors l'histogramme suivant



Cette représentation est difficilement lisible du à notre échelle (en euros). On peut changer d'échelles et passer en milliers d'euros.


i	1	2	3	4	5
Revenus (milliers)	$[0; 1[$	$[1; 2[$	$[2; 3[$	$[3; 4[$	$[4; 6[$
Effectifs n_i	130	232	342	23	12
Fréquences f_i	0.176	0.314	0.463	0.031	0.016
Densité d_i	0.176	0.314	0.463	0.031	0.008



4. Calculez les fréquences cumulées et tracez la fonction de répartition. La fréquence cumulée F_i de la classe i se calcule en ajoutant la fréquence f_i de cette classe et les fréquences des classes précédentes. On a alors (en valeur approchant si on utilise les arrondis précédents)

$$F_1 = 0.176, F_2 = 0.490, F_3 = 0.953, F_4 = 0.984, F_5 = 1.$$

A l'aide de la fréquence cumulée on peut donc tracer la fonction de répartition.



5. Quelle est la proportion d'individus ayant un revenu supérieur ou égal à 3000 euros ? Afin d'avoir la proportion d'individus ayant un revenu strictement supérieur à 3000 euros on peut se référer aux fréquences cumulées. La fréquence cumulée F_3 nous indique la proportion d'individus ayant un revenus se situant dans les classes 1, 2 ou 3 ; c'est à dire la proportion d'individus ayant un revenu inférieur ou égal à 3000 euros. Cette proportion est de 95.3%. En conséquence ceux qui ont un revenu supérieur ou égal à 3000 euros sont les 4.7% restants.
6. Quelle est la proportion d'individus ayant un revenu strictement inférieur à 2000 euros ? Les individus ayant un revenu strictement inférieur à 2000 euros se situent dans les classes 1 et 2. La proportion des individus ayant un revenu strictement inférieur à 2000 euros nous est donc donné par la fréquence cumulée de la classe 2, soit 49%.
7. Le SMIC mensuel net se situe à 1258 euros. Quelle proportion de cet échantillon a un revenu inférieur au SMIC mensuel ? Le SMIC mensuel net étant à 1258 euros, il se situe donc dans la seconde classe ($[1000; 2000[$). On a donc besoin de calculer l'équation de la fonction de répartition sur le morceau $[1000; 2000[$ afin de pouvoir calculer la proportion d'individus qui ont un revenu inférieur ou égal au SMIC mensuel net. La fonction de répartition est une fonction par morceaux dont chaque

morceau est une droite. L'équation a donc la forme $y = a \times x + b$. On obtient le coefficient directeur a avec la formule

$$a = \frac{F_{i+1} - F_i}{e_{i+1} - e_i}.$$

Ce qui ici nous donne

$$a = \frac{0.49 - 0.176}{2000 - 1000} = 0.000314.$$

L'ordonnée à l'origine b s'obtient en remplaçant y et x dans l'équation par les valeurs correspondant à un point sur la droite. On peut prendre le point (2000, 0.49). On a alors

$$\begin{aligned} 0.49 &= 0.000314 \times 2000 + b \\ \Leftrightarrow b &= 0.49 - 0.628 = -0.138. \end{aligned}$$

On a donc que $F(x) = 0.000314 \times x - 0.138$. On peut donc obtenir la fréquence cumulée pour une valeur de x correspondant au SMIC net mensuel. On obtient

$$F(1258) = 0.000314 \times 1258 - 0.138 = 0.257.$$

On peut donc conclure que 25,7% des individus de cet échantillon ont un revenu mensuel net inférieur au SMIC.

EXERCICE 4 : On a observé le nombre de sieste effectuée par un chat sur les jours d'une année. On obtient le tableau suivant

i	1	2	3	4	5	6	7
Nombres de siestes	2	3	4	5	6	7	8
Effectifs n_i	3	10	82	183	78	7	2

1. Quelle est la variable étudiée et quel est son type ? La variable étudiée est le nombre de sieste par jour. C'est une variable quantitative discrète.
2. Calculez la fréquence de chaque modalité. La fréquence f_i est définie par

$$f_i = \frac{n_i}{n}.$$

Il nous faut donc savoir la taille de l'échantillon. Ici $n = 365$ puisque ce sont tous les jours d'une année. Par conséquent on a $f_1 = \frac{3}{365} = 0.008$, $f_2 = \frac{10}{365} = 0.027$, $f_3 = \frac{82}{365} = 0.225$, $f_4 = \frac{183}{365} = 0.501$, $f_5 = \frac{78}{365} = 0.214$, $f_6 = \frac{7}{365} = 0.019$, $f_7 = \frac{2}{365} = 0.005$.


3. Représentez avec le graphique adéquat les résultats de cette observation fondamentale pour la science ? On représente ces fréquences avec un diagramme bâtons.



4. Calculez les fréquences cumulées et tracez la fonction de répartition. La fréquence cumulée F_i de la modalité i se calcule en ajoutant la fréquence f_i de cette modalité et les fréquences des modalités inférieures. On a alors (en valeur approchant si on utilise les arrondis précédents)

$$F_1 = 0.008, F_2 = 0.036, F_3 = 0.260, F_4 = 0.762, F_5 = 0.975, F_6 = 0.994, F_7 = 1.$$

A l'aide de la fréquence cumulée on peut donc tracer la fonction de répartition.



5. Quelle est la proportion de jours pour lesquels le chat a effectué plus de 5 siestes ? La fréquence cumulée de la modalité $i = 4$ nous indique la proportion de jours pour lesquels le chat a effectué 5 siestes ou moins. Cette proportion est de $F_4 = 76.2\%$. Les 23.8% restants représentent donc la proportion de jours pour lesquels le chat a effectué plus de 5 siestes.

6. Quelle est la proportion de jours pour lesquels le chat a effectué 4 siestes ou moins ? La fréquence cumulée de la modalité $i = 3$ nous indique la proportion de jours pour lesquels le chat a effectué 4 siestes ou moins. C'est bien cette fréquence que l'on cherche. Elle est donc de $F_3 = 26\%$.
7. Pour quel nombre de siestes a-t-on une proportion d'observation inférieure ou égale à 80% ? Dans le cas de variables quantitatives discrète on détermine par convention que la valeur pour laquelle la fréquence cumulée est inférieure ou égale à un certains seuil est la première modalité dont la fréquence cumulée dépasse ce seuil. Pour un seuil de 80% c'est donc ici la 5e modalité soit un nombre de siestes égal à 6.

Correction TD 3

EXERCICE 1: Soit le tableau de données agrégées donnant l'âge des employés d'une entreprise :

i	1	2	3	4	5
Classe d'âge	[20; 30[	[30; 40[	[40; 50[	[50; 60[	[60; 65[
Effectifs n_i	12	14	10	8	6

1. Tracer l'histogramme. L'histogramme se construit en utilisant la densité. On définit la densité d_i par l'expression suivante

$$d_i = \frac{f_i}{e_{i+1} - e_i},$$


où e_i représente la borne inférieure de la classe i . Il faut donc dans un premier temps calculer les fréquences.

i	1	2	3	4	5
Classe d'âge	[20; 30[	[30; 40[	[40; 50[	[50; 60[	[60; 65[
Effectifs n_i	12	14	10	8	6
Fréquences f_i	0.24	0.28	0.2	0.16	0.12

Par exemple pour la première classe on a $d_1 = \frac{0.24}{30 - 20} = 0.024$.

i	1	2	3	4	5
Classe d'âge	[20; 30[	[30; 40[	[40; 50[	[50; 60[	[60; 65[
Effectifs n_i	12	14	10	8	6
Fréquences f_i	0.24	0.28	0.2	0.16	0.12
Densités d_i	0.024	0.028	0.02	0.016	0.024


On obtient l'histogramme suivant :



2. Tracer la fonction de répartition. En déduire une estimation du nombre d'employés ayant un âge compris entre 32 et 38 ans. **Afin de tracer la fonction de répartition il nous faut les fréquences cumulées.**

i	1	2	3	4	5
Classe d'âge	[20; 30[	[30; 40[	[40; 50[	[50; 60[	[60; 65[
Effectifs n_i	12	14	10	8	6
Fréquences f_i	0.24	0.28	0.2	0.16	0.12
Densités d_i	0.024	0.028	0.02	0.016	0.024
Fréquences cumulées F_i	0.24	0.52	0.72	0.88	1

Cela nous permet de tracer la fonction de répartition suivante :



Afin d'obtenir la proportion d'individus qui ont entre 32 et 38 il nous faut calculer la proportion d'individus ayant 32 ans ou moins, la proportion d'individus ayant 38 ans ou moins et calculer la différence entre les deux. On va donc devoir calculer l'équation du morceau de la fonction de répartition qui nous intéresse, ici le morceau [30; 40[.

La fonction de répartition est une fonction par morceaux dont chaque morceau est une droite. L'équation a donc la forme $y = a \times x + b$. On obtient le coefficient directeur a avec la formule

$$a = \frac{F_{i+1} - F_i}{e_{i+1} - e_i}.$$

Ce qui ici nous donne

$$a = \frac{0.52 - 0.24}{40 - 30} = 0.028,$$

ce qui correspond à la densité ! L'ordonnée à l'origine b s'obtient en remplaçant y et x dans l'équation par les valeurs correspondant à un point sur la droite. On peut

prendre le point $(30, 0.24)$. On a alors

$$\begin{aligned} 0.24 &= 0.028 \times 30 + b \\ \Leftrightarrow b &= 0.24 - 0.84 = -0.6. \end{aligned}$$

La fonction de répartition sur ce morceau a donc pour équation $F(x) = 0.028x - 0.6$. Les fréquences cumulées pour les âges de 38 et 32 sont donc :

$$\begin{aligned} F(38) &= 0.028 \times 38 - 0.6 = 0.464 \\ F(32) &= 0.028 \times 32 - 0.6 = 0.296. \end{aligned}$$

On sait donc que 46.4% des individus ont 38 ans ou moins et que 29.6% ont 32 ans ou moins. En conséquence, puisque $0.464 - 0.296 = 0.168$, 16.8% des individus ont un âge compris entre 32 et 38 ans.

3. Quel est l'âge moyen des employés de cet entreprise ? Afin de calculer l'âge moyen dans le cas d'une variable quantitative continue regroupée par classe, on fait la moyenne des centres des classes pondérées par les effectifs des classes. La moyenne est le nombre noté $\bar{x}$ défini par

$$\bar{x} = \frac{1}{n} \sum_{i=1}^p n_i \times c_i,$$

avec $c_i = \frac{1}{2}(e_i + e_{i+1})$ le centre de la classe. Ce qui nous donne ici

$$\bar{x} = \frac{1}{50} (25 \times 12 + 35 \times 14 + 45 \times 10 + 55 \times 8 + 62.5 \times 6) = \frac{2055}{50} = 41.1$$

L'âge moyen de notre échantillon est donc de 41.1 ans.

4. Quel est l'âge médian des employés de cet entreprise ? L'âge médian est l'âge pour lequel 50% de l'échantillon est plus jeune et 50% est plus vieux. Il se calcule donc grâce à la fonction de répartition. La classe dans laquelle se situe cet âge médian (la classe médiane) va donc être la classe $[30; 40[$. Nous avons plus haut obtenu déjà l'équation de la fonction de répartition sur ce morceau :

$$F(x) = 0.028 \times x - 0.6$$

On cherche donc x pour lequel $F(x) = 0.5$. On a

$$0.5 = 0.028 \times x - 0.6 \Leftrightarrow x = \frac{1.1}{0.028} = 39.29.$$

L'âge médian est donc de 39.29 ans. Cet âge sépare l'échantillon en deux groupes de proportions égales.

5. Calculer les 1^{er} et 3^e quartiles. Les 1^{er} et 3^e quartiles correspondent respectivement à des niveaux de fréquences cumulées de 0.25 et de 0.75. Le niveau 0.25 se trouve dans la classe $[30; 40[$ et le niveau 0.75 se trouve dans la classe $[50; 60[$. On peut donc déjà calculer le premier quartile :

$$0.25 = 0.028 \times x - 0.6 \Leftrightarrow x = \frac{0.85}{0.028} = 30.36.$$

Le premier quartile est donc de 30.36ans. 25% de l'échantillon a un âge inférieur ou égal à ce nombre.

Pour le 3^e quartile il faut calculer l'équation de la fonction de répartition sur le morceau correspondant. On a alors

$$a = d_4 = 0.016,$$

et donc

$$b = 0.72 - 50 \times 0.016 = -0.08.$$

On peut alors conclure que sur ce morceau l'équation est $F(x) = 0.016 \times x - 0.08$. Par conséquent afin de trouver le 3^e quartile on résout

$$0.75 = 0.016 \times x - 0.08 \Leftrightarrow x = \frac{0.83}{0.016} = 51.88.$$

75% des individus ont donc un âge inférieur à 51.88 ans.


EXERCICE 2: Soit le tableau donnant la répartition du nombre d'accidents par an sur les chaînes de montage des entreprises d'un groupe

i	1	2	3	4	5	6	7	8	9
Nb d'accidents	0	1	2	3	4	5	6	7	8
Effectifs n_i	1	0	1	2	5	5	4	6	2

- Combien y-a-t-il de chaînes de montage dans l'ensemble du groupe ? Il ya 26 chaînes de montages dans l'ensemble du groupe.
- Représentez ces données par un diagramme en bâtons. On va calculer les fréquences et tracer un diagramme en bâtons.

i	1	2	3	4	5	6	7	8	9
Nb d'accidents	0	1	2	3	4	5	6	7	8
Effectifs n_i	1	0	1	2	5	5	4	6	2
Fréquences f_i	0.038	0	0.038	0.077	0.192	0.192	0.154	0.231	0.077

On obtient le diagramme suivant




3. Calculer les effectifs cumulés. On obtient :

i	1	2	3	4	5	6	7	8	9
Nb d'accidents	0	1	2	3	4	5	6	7	8
Effectifs n_i	1	0	1	2	5	5	4	6	2
Fréquences f_i	0.038	0	0.038	0.077	0.192	0.192	0.154	0.231	0.077
Effectifs cumulés	1	1	2	4	9	14	18	24	26

4. Tracer la fonction de répartition. On doit d'abord déterminer les fréquences cumulées que l'on peut calculer depuis les effectifs cumulés ou les fréquences. On obtient

i	1	2	3	4	5	6	7	8	9
Nb d'accidents	0	1	2	3	4	5	6	7	8
Effectifs n_i	1	0	1	2	5	5	4	6	2
Fréquences f_i	0.038	0	0.038	0.077	0.192	0.192	0.154	0.231	0.077
Effectifs cumulés	1	1	2	4	9	14	18	24	26
Fréquences cumulées F_i	0.038	0.038	0.076	0.153	0.345	0.537	0.691	0.922	1

On obtient la fonction de répartition :



5. Calculer le nombre d'accident moyen par an dans le groupe. Dans le cas discret la moyenne est le nombre noté $\bar{x}$ défini par

$$\bar{x} = \frac{1}{n} \sum_{i=1}^p n_i \times x_i.$$

On a donc

$$\bar{x} = \frac{1}{26} (0 \times 1 + 1 \times 0 + 2 \times 1 + 3 \times 2 + 4 \times 5 + 5 \times 5 + 6 \times 4 + 7 \times 6 + 8 \times 2) = 5.5$$

Il y a donc en moyenne 5.5 accidents par chaîne de montage dans le groupe.

6. Déterminer le nombre d'accidents médian. La première modalité pour laquelle la fréquence cumulée dépasse 0.5 est la modalité $i = 6$ soit un nombre médian d'accident par chaîne de montage de 5.

EXERCICE 3 : On a les données suivantes des poids en kg d'un groupe de 30 personnes

45	56	59	59	60	60	61	62	63	63
64	65	65	65	66	67	67	67	68	69
69	69	69	71	72	72	74	77	78	89

1. Calculer le poids moyen et médian. La moyenne dans le cas de données non-agrégées est définie par

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Dans cet exercice on obtient

$$\begin{aligned}\bar{x} &= \frac{1}{30}(45 + 56 + 59 + 59 + 60 + 60 + 61 + 62 + 63 + 63 + 64 + 65 + 65 + 65 + 66 \\ &\quad + 67 + 67 + 67 + 68 + 69 + 69 + 69 + 69 + 71 + 72 + 72 + 74 + 77 + 78 + 89) \\ &= 66.37\end{aligned}$$

Le poids moyen des individus dans l'échantillon est donc de 66.37.

En ce qui concerne le poids médian, c'est l'observation qui divise l'échantillon en deux parts égales. La taille de l'échantillon étant un nombre pair, on a un couple médian. Ici 66 et 67. La médiane est donc au milieu de ces deux nombres, soit 66.5.

2. Déterminer l'étendue de la série de donnée ainsi que l'écart absolu moyen. L'étendue est l'écart entre la plus petite et la plus grande observation. Ici cette étendue est de $89 - 45 = 44$. En ce qui concerne l'écart absolu moyen, il se calcule suivant cette formule :

$$EAM = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|.$$

On calcule les écarts des observations à la moyenne (en valeur absolue et ensuite on fait la moyenne de ces écarts. Dans notre cas on obtient

$$EAM = 5.5.$$

C'est à dire que chaque observation a en moyenne un écart de 5.5 avec la moyenne.

3. Calculer l'écart-type ainsi que la variance. La variance est définie avec cette formule :

$$V(X) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

On obtient dans notre cas une variance de 59.03. L'écart-type est défini comme la racine carré de la variance

$$\sigma(X) = \sqrt{V(X)}.$$

On obtient alors $\sigma(X) = 7.683$. En moyenne, l'écart quadratique à la moyenne est donc de 7.683.

4. Regrouper les données selon les 7 classes : $[45; 55[$, $[55; 60[$, $[60; 65[$, $[65; 70[$, $[70; 75[$, $[75; 80[$, $[80; 90[$. Calculer la moyenne, la variance et l'écart-type par rapport aux centre des classes. En regroupant les données selon les classes on obtient le tableau suivant

i	1	2	3	4	5	6	7
Classe de poids	$[45; 55[$	$[55; 60[$	$[60; 65[$	$[65; 70[$	$[70; 75[$	$[75; 80[$	$[80; 90[$
Effectifs n_i	1	3	7	12	4	2	1

Pour la moyenne on obtient

$$\bar{x} = \frac{1}{30}(1 \times 50 + 3 \times 57.5 + 7 \times 62.5 + 12 \times 67.5 + 4 \times 72.5 + 2 \times 77.5 + 1 \times 85) = 66.67.$$

Pour la variance on va donc considéré comme observation le centre de la classe. On va donc calculer la moyenne des écarts quadratiques entre le centre de la classe c_i et la moyenne des centres, pondérée par l'effectif de chaque classe.

$$V(X) = \frac{1}{n} \sum_{i=1}^p n_i \times (c_i - \bar{x})^2.$$

On obtient

$$V(X) = \frac{1}{30}(1 \times (50 - 66.67)^2 + 3 \times (57.5 - 66.67)^2 + \dots + 1 \times (85 - 66.67)^2) = 45.55.$$

La variance est donc de 45.55 et l'écart type de $\sigma(X) = \sqrt{45.55} = 6.749$.

5. Comparer avec les résultats avec ceux des questions 1 et 3. On observe que l'on obtient des résultats différents à la fois sur la moyenne et sur la variance. La plus grosse différence est sur la variance et l'écart-type. Ce qui est logique : la variance et l'écart-type mesure la dispersion. En regroupant par classe et en calculant la variance par rapport aux centres des classes on réduit la dispersion puisqu'on rend plus homogène les observations appartenant à une même classe. Les 12 observations de la classe $[65; 70[$ valent toutes 67.5 alors que dans nos données brutes elles sont bien plus variées.

EXERCICE 4: On a les notes suivantes pour les étudiant·e·s d'un groupe de TD :

2	5	19	16	17	4	14	4	14	4
4	2	4	17	5	13	19	14	5	3
16	17	18	5	3	18	16	16	4	2

1. Calculer la moyenne, l'écart-type et la variance. En utilisant les mêmes formules qu'à l'exercice précédent on obtient :

$$\begin{aligned}\bar{x} &= 10, \\ V(X) &= 41.47, \\ \sigma(X) &= 6.44.\end{aligned}$$

2. En utilisant ces grandeurs commenter sur l'homogénéité du groupe. Au vu de ces trois mesures on peu observer que malgré le fait d'avoir une moyenne à 10 on a une forte hétérogénéité du groupe puisque l'écart type de 6.44. Cela veut dire qu'en moyenne, un étudiant s'écarte de plus ou moins 6.44 points de la moyenne de l'échantillon ! Cela marque l'existence de deux pôles très distincts.

Correction TD 4

EXERCICE 1: Considérons le tableau suivant regroupant les nombres de diplôme de licence délivrés en 2018 dans une université répartis en fonction du domaine du diplôme et du type de baccalauréat du diplômé.

	Economie-Gestion	LSHS	Sciences
Bac S	70	249	209
Bac ES	129	373	0
Bac L	47	354	0
Bac SMTG	7	31	1
Bac pro	0	19	1
Autre série techno	2	70	6

1. Que représente le nombre 129 à la deuxième ligne et première colonne du tableau ? 129 représente le nombre de diplôme en Economie-Gestion délivré en 2018 à des étudiant·e·s diplômé·e·s du baccalauréat ES.
2. Reproduisez ce tableau en ajoutant les effectifs marginaux. Les effectifs marginaux lignes s'obtiennent pour chaque ligne en faisant la somme des effectifs de cette ligne. Réciproquement pour les effectifs marginaux colonnes. On obtient

	Economie-Gestion	LSHS	Sciences	Total
Bac S	70	249	209	528
Bac ES	129	373	0	502
Bac L	47	354	0	401
Bac SMTG	7	31	1	39
Bac pro	0	19	1	20
Autre série techno	2	70	6	78
Total	255	1096	217	1568

3. A partir du tableau obtenu à la question 2, construisez un nouveau tableau des fréquences conjointes. Afin d'avoir le tableau des fréquences conjointes on divise chaque effectif par l'effectif total de l'échantillon (ici 1568). On obtient

	Economie-Gestion	LSHS	Sciences	Total
Bac S	0.04	0.16	0.13	0.34
Bac ES	0.08	0.24	0.00	0.32
Bac L	0.03	0.23	0.00	0.26
Bac SMTG	0.00	0.02	0.00	0.02
Bac pro	0.00	0.01	0.00	0.01
Autre série techno	0.001	0.045	0.004	0.05
Total	0.16	0.70	0.14	1

4. Sur l'ensemble des diplômés, quelle proportion ont obtenu leur diplôme en Economie-Gestion ? La proportion de diplômés ayant reçu leurs diplômes en Economie-Gestion est de 16%.
5. Construisez le tableau des fréquences conditionnelles du type de Bac selon le diplôme de licence. Les fréquences conditionnelles du type de Bac selon le diplôme de licence s'obtiennent en divisant chaque case du tableau par son effectif marginal colonne.

	Economie-Gestion	LSHS	Sciences
Bac S	0.27	0.23	0.96
Bac ES	0.51	0.34	0.00
Bac L	0.18	0.32	0.00
Bac SMTG	0.03	0.03	0.005
Bac pro	0.00	0.02	0.005
Autre série techno	0.01	0.06	0.03
Total	1	1	1

6. Quelle proportion des diplômés en LSHS les détenteurs d'un bac ES représentent-ils ? Les diplômés en LSHS qui sont détenteurs d'un bac ES représentent 34% de l'ensemble des diplômés en LSHS.
7. Construisez le tableau des fréquences conditionnelles du diplôme de licence selon le type de Bac. Les fréquences conditionnelles du type de Bac selon le diplôme de licence s'obtiennent en divisant chaque case du tableau par son effectif marginal ligne.

	Economie-Gestion	LSHS	Sciences	Total
Bac S	0.13	0.47	0.40	1
Bac ES	0.26	0.74	0.00	1
Bac L	0.12	0.88	0.00	1
Bac SMTG	0.18	0.79	0.03	1
Bac pro	0.00	0.95	0.05	1
Autre série techno	0.02	0.90	0.08	1

8. Parmi les diplômés de licence étant détenteurs d'un bac Pro, quelle proportion a obtenu une licence de LSHS ? Parmi les diplômés de licence ayant un bac Pro, 95% d'entre eux ont obtenus leur licence en LSHS.

EXERCICE 2: On considère le tableau suivant qui indique la répartition de 900 familles selon le nombre d'enfants (0 à 4) et le nombre de pièces du logement qu'elles habitent (1 à 6).

P \ E	0	1	2	3	4
1	8	7	4	1	0
2	42	58	42	3	1
3	28	72	124	51	9
4	11	55	84	101	21
5	4	23	90	26	20
6	1	2	4	3	5

1. Que représente le nombre 124 à la troisième ligne et troisième colonne ? **Ce nombre indique que parmi les 900 familles considérées, 124 avaient 2 enfants et vivaient dans un logement 3 pièces.**
2. A partir de ce tableau, construisez un nouveau tableau indiquant les fréquences conjointes. **Afin d'avoir le tableau des fréquences conjointes on divise chaque effectif par l'effectif total de l'échantillon (ici 900). On obtient**

P \ E	0	1	2	3	4	Total
1	0.009	0.008	0.004	0.001	0	0.022
2	0.047	0.064	0.047	0.003	0.001	0.162
3	0.031	0.080	0.138	0.057	0.010	0.316
4	0.012	0.061	0.093	0.112	0.023	0.302
5	0.004	0.026	0.100	0.029	0.022	0.181
6	0.001	0.002	0.004	0.003	0.006	0.017
Total	0.104	0.241	0.387	0.206	0.062	1

3. Calculez la moyenne marginale du nombre de pièces. Qu'est-ce que ce nombre représente ? **Afin d'obtenir la moyenne marginale du nombre de pièce on peut multiplier chaque modalité de la variable du nombre de pièces par sa fréquence marginale et faire la somme de ces nombres. On peut également l'obtenir en calculant la moyenne de la variable "Nombre de pièces" de la même manière que si on ne considérait que cette variable. On a**

$$\bar{P} = \sum_{i=1}^6 f_{\bullet i} \times P_i = \frac{1}{900} \sum_{i=1}^6 n_{\bullet i} \times P_i$$

On obtient alors 3.507. Ainsi on sait qu'en moyenne, dans notre échantillon, les familles vivent dans un logement ayant au moins 3 pièces (3 pièces et demi précisément).

4. Calculez la moyenne marginale ainsi que la variance empirique marginale du nombre d'enfant. Qu'est-ce que ces nombres représentent ? **On calcule de la même manière que précédemment la moyenne marginale pour le nombre d'enfants. On a**

$$\bar{E} = \sum_{j=1}^5 f_{j\bullet} \times E_j = 1.88.$$

La variance est quand à elle égale à

$$V(E) = \sum_{j=1}^5 n_{\bullet j} (E_j - \bar{E})^2 = 1.099.$$

La variance s'interprète difficilement, on va donc calculer l'écart-type $\sigma(E) = \sqrt{V(E)} = 1.048$. On en déduit donc qu'une famille moyenne de notre échantillon est composée de presque deux enfants, avec un écart de plus ou moins 1 enfant autour de cette moyenne.

5. Calculez les moyennes conditionnelles ainsi que les variances conditionnelles pour le nombre d'enfant et le nombre de pièces. Afin de calculer les moyennes conditionnelles du nombre d'enfant selon le nombre de pièces on procède de la sorte : On fixe un nombre de pièces P_i . Pour ce nombre de pièces donnée on calcule la moyenne du nombre d'enfants des familles qui vivent dans un logement ayant ce nombre de pièces. Ainsi

$$\bar{E}_{P_i} = \frac{1}{n_{i\bullet}} \sum_{j=1}^5 n_{ij} * E_j.$$

Et réciproquement pour

$$\bar{P}_{E_j} = \frac{1}{n_{\bullet j}} \sum_{i=1}^6 n_{ij} * P_i.$$

On obtient

$$\begin{aligned} \bar{P}_0 &= 2.62, \bar{P}_1 = 3.16, \bar{P}_2 = 3.65, \bar{P}_3 = 3.85, \bar{P}_4 = 4.34, \\ \bar{E}_1 &= 0.90, \bar{E}_2 = 1.06, \bar{E}_3 = 1.79, \bar{E}_4 = 2.24, \bar{E}_5 = 2.21, \bar{E}_6 = 2.60. \end{aligned}$$

En ce qui concerne les variances conditionnelles du nombre de pièces selon le nombre d'enfants on procède de la sorte : On fixe un nombre d'enfants E_i . Pour ce nombre d'enfants donnée on calcul la variance du nombre de pièces des familles qui ont ce nombre d'enfants. Ainsi

$$V(P_{E_j}) = \frac{1}{n_{\bullet j}} \sum_{i=1}^6 n_{ij} (P_i - \bar{P}_{E_j})^2.$$

Réciproquement

$$V(E_{P_i}) = \frac{1}{n_{i\bullet}} \sum_{j=1}^5 n_{ij} (E_j - \bar{E}_{P_i})^2.$$

On obtient alors

$$\begin{aligned} V(P_0) &= 1.02, V(P_1) = 1.13, V(P_2) = 1.12, V(P_3) = 0.57, V(P_4) = 0.83, \\ V(E_1) &= 0.79, V(E_2) = 0.72, V(E_3) = 0.91, V(E_4) = 0.99, V(E_5) = 0.84, V(E_6) = 1.57. \end{aligned}$$

On constate donc une augmentation du nombre de pièces moyen à mesure que le nombre d'enfant augmente ainsi qu'une augmentation du nombre d'enfants moyen à mesure que le nombre de pièces augmente. On peut également observer par exemple que quand le nombre de pièces augmentent, les variances du nombres d'enfants restent à peu près constantes, sauf quand on atteint 6 pièces.

6. Calculez la covariance entre les deux variables du tableau. La covariance entre deux variables X et Y est défini par

$$Cov(X, Y) = \frac{1}{n} \sum_{i=1} n(x_i - \bar{x})(y_i - \bar{y}).$$

Dans le cas de données agrégées cela devient

$$Cov(X, Y) = \frac{1}{n} \sum_{i=1}^p \sum_{j=1}^q n_{ij}(x_i - \bar{x})(y_j - \bar{y}).$$

Si on esquisse le début du calcul dans notre cas on a

$$\begin{aligned} Cov(P, E) &= \frac{1}{900} \sum_{i=1}^6 \sum_{j=1}^5 n_{ij}(P_i - \bar{P})(E_j - \bar{E}) \\ &= \frac{1}{900} [n_{11}(P_1 - \bar{P})(E_1 - \bar{E}) + n_{12}(P_1 - \bar{P})(E_2 - \bar{E}) + n_{13}(P_1 - \bar{P})(E_3 - \bar{E}) \\ &\quad + n_{14}(P_1 - \bar{P})(E_4 - \bar{E}) + n_{15}(P_1 - \bar{P})(E_5 - \bar{E}) \\ &\quad + n_{21}(P_2 - \bar{P})(E_1 - \bar{E}) + n_{22}(P_2 - \bar{P})(E_2 - \bar{E}) + n_{23}(P_2 - \bar{P})(E_3 - \bar{E}) \\ &\quad + n_{24}(P_2 - \bar{P})(E_4 - \bar{E}) + n_{25}(P_2 - \bar{P})(E_5 - \bar{E}) \\ &\quad + \dots] \end{aligned}$$

Après calcul on obtient $Cov(P, E) = 0.4431$.

7. Pourquoi ne vous a-t-on pas demandé de calculer des moyennes et variances pour le tableau de l'exercice 1 ? Les moyennes et variances sont des indicateurs définis uniquement pour des variables quantitatives. L'exercice précédent portaient sur des variables qualitatives.


TD 5 - Régression linéaire simple à deux variables

EXERCICE 1: On considère la série statistique donnée par le tableau suivant

i	1	2	3	4	5	6	7	8	9	10
x_i	13	15	8	13	14	17	27	18	27	21
y_i	64	90	79	81	88	68	139	78	114	52

On cherche à expliquer la valeur des y par la valeur des x

1. Tracer le nuage de points. Afin de tracer le nuage de points on considère chaque individu comme un points défini par ses coordonnées en X et Y



2. Calculer la moyenne et la variance des x . Pour obtenir la moyenne des X on applique la formule

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

On obtient dans notre cas

$$\bar{x} = \frac{1}{10}(13 + 15 + 8 + 13 + 14 + 17 + 27 + 18 + 27 + 21) = 17.3.$$

Les individus prennent donc une valeur de X qui est en moyenne égale à 17.3. Pour la variance on applique la formule

$$\begin{aligned} V(X) &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \\ &= \left(\frac{1}{n} \sum_{i=1}^n x_i^2 \right) - \bar{x}^2. \end{aligned}$$

En conséquence on obtient

$$\begin{aligned} V(X) &= \frac{1}{10}(13^2 + 15^2 + 8^2 + 13^2 + 14^2 + 17^2 + 27^2 + 18^2 + 27^2 + 21^2) - 17.3^2 \\ &= 34.21 \end{aligned}$$

3. Calculer la covariance entre x et y . Pour obtenir la covariance entre les X et Y on applique la formule

$$\begin{aligned} Cov(X, Y) &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \\ &= \left(\frac{1}{n} \sum_{i=1}^n x_i y_i \right) - \bar{x}\bar{y}. \end{aligned}$$

Il nous faut donc calculer $\bar{y}$ que l'on obtient ainsi

$$\bar{y} = \frac{1}{10}(64 + 90 + 79 + 81 + 88 + 68 + 139 + 78 + 114 + 52) = 85.3.$$

Pour la covariance on obtient alors

$$\begin{aligned} Cov(X, Y) &= \frac{1}{10}(13 \times 64 + 15 \times 90 + 8 \times 79 + 13 \times 81 + 14 \times 88 + 17 \times 68 + 27 \times 139 \\ &\quad + 18 \times 78 + 27 \times 114 + 21 \times 52) - 17.3 \times 85.3 \\ &= 82.51 \end{aligned}$$

On peut donc en conclure qu'il existe un lien positif entre X et Y . Quand X augmente, Y augmente également.

4. Déterminer l'équation de la droite de régression entre x et y . L'équation de la droite de régression entre X et Y est de la forme $y = ax + b$ avec $a = \frac{Cov(X, Y)}{V(X)}$ et $b = \bar{y} - a\bar{x}$. On obtient donc (valeurs arrondies) :

$$\begin{aligned} a &= \frac{82.51}{34.21} = 2.41 \\ b &= 85.3 - 2.41 \times 17.3 = 85.3 - 41.7 = 43.6. \end{aligned}$$

L'équation de la droite est donc

$$y = 2.41x + 43.6.$$

EXERCICE 2: Nous avons les données suivantes sur le taux de pauvreté (pourcentage de ménage sous le seuil de pauvreté fédéral) et le taux de natalité pour les mineurs entre 15 et 19 ans (pour 1000) pour tous les états des états unis pour l'année 2002.

State	Alab	Alask	Ari	Ark	Cali	Colo	Conn	Dela	Colu	Flor	Geor
Poverty	20.1	7.1	16.1	14.9	16.7	8.8	9.7	10.3	22	16.2	12.1
TeenBirth	54.5	39.5	61.2	59.9	41.1	47	25.8	46.3	69.1	44.5	55.7
State	Hawa	Idah	Illi	Indi	Iowa	Kans	Kent	Loui	Main	Mary	Mass
Poverty	10.3	14.5	12.4	9.6	12.2	10.8	14.7	19.7	11.2	10.1	11
TeenBirth	38.2	39.1	42.2	44.6	32.5	43	51	58.1	25.4	35.4	23.3
State	Mich	Minn	Missi	Misso	Mont	Nebr	Neva	NewH	NewJ	NewM	NewY
Poverty	12.2	9.2	23.5	9.4	15.3	9.6	11.1	5.3	7.8	25.3	16.5
TeenBirth	34.8	27.5	64.7	44.1	36.4	37	53.9	20	26.8	62.4	29.5
State	NCar	NDak	Ohio	Okla	Oreg	Penn	Rhod	SCar	SDak	Tenn	Texa
Poverty	12.6	12	11.5	17.1	11.2	12.2	10.6	19.9	14.5	15.5	17.4
TeenBirth	52.2	27.2	39.5	58	36.8	31.6	35.6	53	38	54.3	64.4
State	Uta	Verm	Virg	Wash	WVir	Wisc	Wyom				
Poverty	8.4	10.3	10.2	12.5	16.7	8.5	12.2				
TeenBirth	36.8	24.2	37.6	33	45.5	32.3	39.9				

On cherche un lien entre ces deux indicateurs.

1. Calculer la covariance ainsi que le coefficient de corrélation entre le taux de pauvreté et le taux de natalité chez les adolescentes. **Afin de calculer la covariance et le coefficient de corrélation, il faut au préalable calculer les moyennes et les variances.** Vu que les données sont nombreuses on peut utiliser un tableau pour noter les étapes intermédiaires et calculer les variances et covariances grâce à leur formules simplifiées (voir propriétés du cours et exercice précédent). On note x la variable “Poverty” et y la variable “TeenBirth”.

x_i	y_i	x_i^2	y_i^2	$x_i y_i$
20.1	54.5	404.01	2970.25	1095.45
7.1	39.5	50.41	156.25	280.45
16.1	61.2	259.21	3745.44	985.32
14.9	59.9	222.01	3588.01	892.51
16.7	41.1	278.89	1689.21	686.37
8.8	47	77.44	2209	413.6
9.7	25.8	94.09	665.64	250.26
10.3	46.3	106.09	2143.69	476.89
22	69.1	484	4774.81	1520.2
16.2	44.5	262.44	1980.25	720.9
12.1	55.7	146.41	3102.49	673.97
10.3	38.2	106.09	1459.24	393.46
14.5	39.1	210.25	1528.81	566.95
12.4	42.2	153.76	1780.84	523.28
9.6	44.6	92.16	1989.16	428.16
12.2	32.5	148.84	1056.25	396.5
10.8	43	116.64	1849	464.4
14.7	51	216.09	2601	749.7
19.7	58.1	388.09	3375.61	1144.57
11.2	25.4	125.44	645.16	284.48
10.1	35.4	102.01	1253.16	357.54
11	23.3	121	542.89	256.3
12.2	34.8	148.84	1211.04	424.56
9.2	27.5	84.64	756.25	253
23.5	64.7	552.25	4186.09	1520.45
9.4	44.1	88.36	1944.81	414.54
15.3	36.4	234.09	1324.96	556.92
9.6	37	92.16	1369	355.2
11.1	53.9	123.21	2905.21	598.29
5.3	20	28.09	400	106
7.8	26.8	60.84	718.24	209.04
25.3	62.4	640.09	3893.76	1578.72
16.5	29.5	272.25	870.25	486.75
12.6	52.2	158.76	2724.84	657.72
12	27.2	144	739.84	326.4
11.5	39.5	132.25	1560.25	454.25
17.1	58	292.41	3364	991.8

	x_i	y_i	x_i^2	y_i^2	$x_i y_i$
	11.2	36.8	125.44	1354.24	412.16
	12.2	31.6	148.84	998.56	358.52
	10.6	35.6	112.36	1267.36	377.36
	19.9	53	396.01	2809	1054.7
	14.5	38	210.25	1444	551
	15.5	54.3	240.25	2948.49	841.65
	17.4	64.4	302.76	4147.36	1120.56
	8.4	36.8	70.56	1354.24	309.12
	10.3	24.2	106.09	585.64	249.26
	10.2	37.6	104.04	1413.76	383.52
	12.5	33	156.25	1089	412.5
	16.7	45.5	278.89	2070.25	459.85
	8.5	32.3	72.25	1043.29	274.55
	12.2	39.9	148.84	1592.01	486.78
Somme	669	2154.4	9640.44	98595.9	30113.43
Moyenne	13.12	42.24	190.00	1933.25	590.46

On a donc

$$\bar{x} = 13.12, \bar{y} = 42.24,$$

$$\frac{1}{n} \sum_{i=1}^n x_i^2 = 190, \frac{1}{n} \sum_{i=1}^n y_i^2 = 1933.25,$$

$$\frac{1}{n} \sum_{i=1}^n x_i y_i = 590.46.$$

On en déduit donc que

$$V(X) = 190 - 13.12^2 = 17.87, V(Y) = 1933.25 - 42.24^2 = 149.03$$

$$\sigma(X) = \sqrt{17.87} = 4.23, \sigma(Y) = 12.20.$$

On peut alors calculer la covariance et le coefficient de corrélation :

$$Cov(X, Y) = 590.46 - 13.12 \times 42.24 = 36.24$$

$$r(X, Y) = \frac{36.24}{4.23 \times 12.20} = 0.70.$$

En conséquence, le taux de pauvreté moyen des états est de 13.12% plus ou moins 4.23 points de pourcentage. Le taux moyen de natalité chez les adolescentes est de 42.24 pour mille plus ou moins 12.20 points. Ces deux variables sont liés positivement (elles évoluent dans le même sens) et leurs corrélation est de 70%, ce qui est élevé.

2. Déterminer l'équation de la droite de régression. Nous avons toutes les informations nécessaires pour calculer les paramètres de la droite de régression $Y = aX + b$.

$$a = \frac{Cov(X, Y)}{V(X)} = \frac{36.24}{17.87} = 2.03$$

$$b = \bar{y} - a\bar{x} = 42.24 - 2.03 \times 13.12 = 15.61.$$

L'équation de la droite de régression est donc $Y = 2.03X + 15.61$.

3. Calculer les résidus. En utilisant la formule de la droite de régression on peut estimer des valeurs de Y en fonction des valeurs de X . On va appeler ces estimations $\hat{Y}$. La différence entre les valeurs observées de Y et les valeurs estimées sont les résidus. On va donc d'abord calculer les $\hat{Y}$. Encore une fois on va utiliser un tableau pour présenter les résultats.

	y_i	$\hat{y}_i$	$y_i - \hat{y}_i$	$\hat{y}_i - \bar{y}$	$(y_i - \hat{y}_i)^2$	$(\hat{y}_i - \bar{y})^2$
	54.5	56.4	-1.9	14.2	3.7	200.8
	39.5	30.0	9.5	-12.2	89.8	149.3
	61.2	48.3	12.9	6.0	166.6	36.6
	59.9	45.9	14.0	3.6	197.2	13.1
	41.1	49.5	-8.4	7.3	70.7	52.8
	47.0	33.5	13.5	-8.8	183.0	76.9
	25.8	35.3	-9.5	-6.9	90.3	48.2
	46.3	36.5	9.8	-5.7	95.7	32.8
	69.1	60.3	8.8	18.0	78.0	325.0
	44.5	48.5	-4.0	6.3	16.0	39.1
	55.7	40.2	15.5	-2.1	241.1	4.3
	38.2	36.5	1.7	-5.7	2.8	32.8
	39.1	45.0	-5.9	2.8	35.3	7.9
	42.2	40.8	1.4	-1.5	2.0	2.1
	44.6	35.1	9.5	-7.1	90.3	51.1
	32.5	40.4	-7.9	-1.9	62.0	3.5
	43.0	37.5	5.5	-4.7	29.9	22.2
	51.0	45.5	5.5	3.2	30.8	10.3
	58.1	55.6	2.5	13.4	6.2	178.4
	25.4	38.3	-12.9	-3.9	167.6	15.2
	35.4	36.1	-0.7	-6.1	0.5	37.6
	23.3	37.9	-14.6	-4.3	214.3	18.5
	34.8	40.4	-5.6	-1.9	31.1	3.5
	27.5	34.3	-6.8	-8.0	46.0	63.3
	64.7	63.3	1.4	21.1	1.9	444.0
	44.1	34.7	9.4	-7.6	88.5	57.0
	36.4	46.7	-10.3	4.4	105.5	19.6
	37.0	35.1	1.9	-7.1	3.6	51.1
	53.9	38.1	15.8	-4.1	248.3	16.8
	20.0	26.4	-6.4	-15.9	40.6	252.0
	26.8	31.4	-4.6	-10.8	21.6	116.6
	62.4	67.0	-4.6	24.7	20.9	611.4
	29.5	49.1	-19.6	6.9	384.4	47.1
	52.2	41.2	11.0	-1.1	121.3	1.1
	27.2	40.0	-12.8	-2.3	163.1	5.2
	39.5	39.0	0.5	-3.3	0.3	10.8
	58.0	50.3	7.7	8.1	58.9	65.3

	y_i	$\hat{y}_i$	$y_i - \hat{y}_i$	$\hat{y}_i - \bar{y}$	$(y_i - \hat{y}_i)^2$	$(\hat{y}_i - \bar{y})^2$
	36.8	38.3	-1.5	-3.9	2.4	15.2
	31.6	40.4	-8.8	-1.9	77.0	3.5
	35.6	37.1	-1.5	-5.1	2.3	26.2
	53.0	56.0	-3.0	13.8	9.0	189.4
	38.0	45.0	-7.0	2.8	49.6	7.9
	54.3	47.1	7.2	4.8	52.2	23.3
	64.4	50.9	13.5	8.7	181.4	75.5
	36.8	32.7	4.1	-9.6	17.1	91.8
	24.2	36.5	-12.3	-5.7	151.8	32.8
	37.6	36.3	1.3	-5.9	1.6	35.1
	33.0	41.0	-8.0	-1.3	63.8	1.6
	45.5	49.5	-4.0	7.3	16.1	52.8
	32.3	32.9	-0.6	-9.4	0.3	87.9
	39.9	40.4	-0.5	-1.9	0.2	3.5
Somme					3834.6	3769.5

4. Calculer la somme des carrés expliqués ainsi que la somme des carrés des résidus. On a donc la somme des carrés des résidus est égale à 3834.6 et la somme des carrés expliqués à 3769.5.
5. Déterminer le coefficient de détermination R^2 . Le R^2 se calcule de plusieurs manières. Tout d'abord on peut le calculer comme le rapport entre la somme des carrés expliqués et la somme des carrés totaux. La somme des carrés totaux étant égal à n fois la variance de Y .

$$R^2 = \frac{3769.5}{51 \times 149.03} = 0.49.$$

On peut le calculer en faisant également 1 moins le rapport entre la somme des carrés des résidus et la somme des carrés totaux :

$$R^2 = 1 - \frac{3834.6}{51 \times 149.03} = 0.49.$$


Enfin on peut le calculer comme le carré du coefficient de corrélation, soit

$$R^2 = r(X, Y)^2 = 0.7^2 = 0.49.$$

EXERCICE 3 : On considère les données annuelles suivantes. Elles représentent le nombre de personne mortes noyées après être tombées d'un bateau de pêche (aux états-unis) et le taux de mariage (pour 1000 habitants) au Kentucky.

Année	99	00	01	02	03	04	05	06	07	08	09	10
Noyade	19	16	9	12	15	10	11	7	2	5	1	1
Mariage	10.9	9.8	9	9	9.1	8.8	8.7	8.4	7.8	7.9	7.6	7.4

1. Tracer le nuage de points Afin de tracer le nuage de points on considère chaque individu comme un points défini par ses coordonnées en X et Y . On va prendre Y le nombre de noyade et X le taux de mariage.



2. Une régression linéaire vous semble-t-elle pertinente au vu du nuage de points ?
Au vu du nuage de point on a effectivement l'impression qu'une régression linéaire semble pertinente. Les points sont proche d'un alignement parfait.
3. Calculer le coefficient de corrélation linéaire entre ces deux indicateurs. Pour le coefficient de corrélation linéaire il nous faut la covariance et les écarts types. Nous allons refaire un tableau comme à l'exercice précédent.

	x_i	y_i	x_i^2	y_i^2	$x_i y_i$
	10,9	19,0	118,8	361,0	207,1
	9,8	16,0	96,0	256,0	156,8
	9,0	9,0	81,0	81,0	81,0
	9,0	12,0	81,0	144,0	108,0
	9,1	15,0	82,8	225,0	136,5
	8,8	10,0	77,4	100,0	88,0
	8,7	11,0	75,7	121,0	95,7
	8,4	7,0	70,6	49,0	58,8
	7,8	2,0	60,8	4,0	15,6
	7,9	5,0	62,4	25,0	39,5
	7,6	1,0	57,8	1,0	7,6
	7,4	1,0	54,8	1,0	7,4
Somme	104,4	108,0	919,1	1368,0	1002,0
Moyenne	8,7	9,0	76,6	114,0	83,5

On a donc

$$\begin{aligned}\bar{x} &= 8.7, \bar{y} = 9, \\ \frac{1}{n} \sum_{i=1}^n x_i^2 &= 76.6, \frac{1}{n} \sum_{i=1}^n y_i^2 = 114, \\ \frac{1}{n} \sum_{i=1}^n x_i y_i &= 83.5.\end{aligned}$$

On en déduit donc que

$$\begin{aligned}V(X) &= 76.6 - 8.7^2 = 0.9, V(Y) = 114 - 9^2 = 33 \\ \sigma(X) &= \sqrt{0.9} = 0.95, \sigma(Y) = 5.74.\end{aligned}$$

On peut alors calculer la covariance et le coefficient de corrélation :

$$\begin{aligned}Cov(X, Y) &= 83.5 - 8.7 \times 9 = 5.2 \\ r(X, Y) &= \frac{5.2}{0.95 \times 5.74} = 0.95.\end{aligned}$$

En conséquence, le taux de mariage moyen au Kentucky est de 8.7 pour mille habitants sur la période considéré, plus ou moins 0.95 points. Le nombre de noyade en tombant d'un bateau de pêche aux états-unis est en moyenne de 9 par an sur la période plus ou moins 5.74. Ces deux variables sont liées positivement (elles évoluent dans le même sens) et leurs corrélation est de 95%, ce qui est extrêmement élevé.

4. Déterminer l'équation de la droite de régression ainsi que le coefficient de détermination R^2 . L'équation de la droite de régression entre X et Y est de la forme $y = ax + b$ avec $a = \frac{Cov(X,Y)}{V(X)}$ et $b = \bar{y} - a\bar{x}$. On obtient donc (valeurs arrondies) :

$$\begin{aligned}a &= \frac{5.2}{0.9} = 5.8 \\ b &= 9 - 5.8 \times 8.7 = 9 - 50.5 = -41.5.\end{aligned}$$

L'équation est de la droite est donc

$$y = 5.8x - 41.5.$$

Afin d'obtenir le coefficient de détermination, on peut simplement prendre le carré du coefficient de corrélation. On obtient

$$R^2 = r(X, Y)^2 = 0.95^2 = 0.90.$$

Ce qui est très élevé. La droite de régression permet de bien expliquer les valeurs de Y .

5. Au vu des données et des réponses aux questions précédentes, que pensez vous de la maxime “ corrélation n’est pas nécessairement causalité” ? **On peut difficilement imaginer un lien causal entre ces deux variables. C’est donc important de bien retenir que la corrélation n’est pas synonyme de causalité. Ici la corrélation est très importante mais ces deux variables n’ont vraisemblablement aucune influence l’une sur l’autre.**

EXERCICE 4: Le tableau suivant regroupe les températures moyennes annuelles de quelques grandes villes françaises ainsi que leur latitude.

Ville	Bordeaux	Brest	Clermont	Grenoble	Lille
Lattitude	44.5	48.24	45.47	45.1	50.38
Temp. Moy.	13.33	10.77	10.94	10.98	9.73
Ville	Lyon	Marseille	Montpellier	Nantes	Nice
Lattitude	45.45	43.18	43.36	47.13	43.42
Temp. Moy	11.36	14.23	13.89	11.69	14.84
Ville	Paris	Rennes	Strasbourg	Toulouse	Vichy
Lattitude	48.52	48.05	48.35	43.36	46.08
Temp. Moy.	11.18	11.13	9.72	12.68	10.72

1. Calculer la température moyenne pour l’ensemble des villes ainsi que la latitude moyenne. **Comme pour les exercices précédents, on va construire un tableau afin de calculer directement l’ensemble des valeurs qui nous permettrons de répondre aux questions suivantes. On va poser X la latitude et Y la température moyenne :**

	x_i	y_i	x_i^2	y_i^2	$x_i y_i$
	44.50	13.33	1980.25	177.69	593.19
	48.24	10.77	2327.10	115.99	519.54
	45.47	10.94	2067.52	119.68	497.44
	45.10	10.98	2034.01	120.56	495.20
	50.38	9.73	2538.14	94.67	490.20
	45.45	11.36	2065.70	129.05	516.31
	43.18	14.23	1864.51	202.49	614.45
	43.36	13.89	1880.09	192.93	602.27
	47.13	11.69	2221.24	136.66	550.95
	43.42	14.84	1885.30	220.23	644.35
	48.52	11.18	2354.19	124.99	542.45
	48.05	11.13	2308.80	123.88	534.80
	48.35	9.72	2337.72	94.48	469.96
	43.36	12.68	1880.09	160.78	549.80
	46.08	10.72	2123.37	114.92	493.98
Somme	690.59	177.19	31868.03	2129.00	8114.90
Moyenne	46.04	11.81	2124.54	141.93	540.99

La latitude moyenne est donc de 46.04 et la température annuelle moyenne en moyenne de 11.81 degrés.

2. Calculer la variance de chacune des deux variables. On obtient :

$$V(X) = 2124.54 - 46.04^2 = 2124.54 - 2119.68 = 4.86$$

$$V(Y) = 141.93 - 11.81^2 = 141.93 - 139.48 = 2.45.$$

On peut également en déduire les écarts-type :

$$\sigma(X) = \sqrt{4.86} = 2.20, \sigma(Y) = \sqrt{2.45} = 1.57.$$

3. Déterminer la covariance ainsi que le coefficient de corrélation entre la latitude et la température moyenne annuelle. On obtient

$$Cov(X, Y) = 540.99 - 46.04 \times 11.81 = 540.99 - 543.73 = -2.74$$

$$r(X, Y) = \frac{-2.74}{2.20 \times 1.57} = -0.79.$$

On a donc une corrélation négative forte entre les deux variables. Plus la latitude augmente (plus on se situe au nord) plus la température moyenne annuelle des villes diminue.

4. Déterminer l'équation de la droite de régression linéaire. L'équation de la droite de régression entre X et Y est de la forme $y = ax + b$ avec $a = \frac{Cov(X, Y)}{V(X)}$ et $b = \bar{y} - a\bar{x}$. On obtient donc (valeurs arrondies) :

$$a = \frac{2.74}{4.86} = 0.56$$

$$b = 11.81 - 0.56 \times 46.04 = 11.81 - 25.78 = -13.97.$$

L'équation est de la droite est donc

$$y = 0.56x - 13.97.$$

5. La ville d'Angers a une latitude de 47.28. Quelle est la température moyenne annuelle prédite par le modèle ? La ville d'Angers a une latitude de 47.28. Afin d'obtenir la température moyenne annuelle prédite par la droite de régression on remplace x par 47.28 dans l'équation de la droite. On obtient

$$y = 0.56 \times 47.28 - 13.97 = 12.50.$$

On peut donc estimer, d'après nos régression linéaire, que la ville d'Angers doit avoir une température annuelle moyenne située autour de 12.50 degrés.

6. Calculer le coefficient de détermination. Afin de calculer le coefficient de détermination on peut calculer le carré du coefficient de corrélation linéaire :

$$R^2 = r(X, Y)^2 = 0.62.$$

La régression permet donc d'expliquer 62% de la dispersion des températures annuelles moyenne.